

Universität Stuttgart

Master Thesis

基于在线强化学习的编码器故障

鲁棒机器人操作策略研究

Fault-Resilient Robot Manipulation via Online
Reinforcement Learning under Encoder Calibration Bias

程程 Cheng Cheng

Examiner: Prof. Dr. TODO

Supervisor: TODO, M.Sc.

开始日期: TODO

结束日期: TODO

摘要

工业机器人编码器校准偏差会引入系统性误差，同时腐蚀控制回路（通过错误的雅可比矩阵计算）和状态观测（通过错误的正运动学），使机器人控制问题从完全可观测的马尔可夫决策过程（MDP）退化为部分可观测马尔可夫决策过程（POMDP）。本文研究在未知编码器偏差下，如何在不停机重新标定的前提下保持鲁棒的操作性能。

首先，我们将编码器偏差问题形式化为 POMDP，其中偏差向量作为 episode 级隐变量使真实关节状态不可观测。通过可观测性分析，我们证明标准本体感觉观测不足以区分不同的偏差条件，而引入外部末端执行器位置信号可以恢复近似可观测性——有效地将 POMDP 还原为可用标准强化学习算法求解的 MDP。

基于上述分析，我们提出一个两层系统：(1) **鲁棒任务策略**，采用 RLDP 在随机编码器偏差下训练，在模拟抓取任务上全偏差范围 $[0, 0.3]$ rad 内达到 92–100% 成功率；(2) **安全备份策略**，通过主动避碰保护人在回路训练过程中的人类操作者安全。域随机化技术弥合了备份策略的仿真-真机差距。

消融实验证实外部位置信号对偏差鲁棒性能是必要的，验证了理论可观测性分析。我们还提出了面向 Franka Panda 真机的部署方案，包括双注入点故障注入机制，可在物理硬件上忠实复现编码器偏差因果链。

关键词：部分可观测马尔可夫决策过程；强化学习；容错控制；编码器偏差；机器人操作

Abstract

Encoder calibration bias in industrial robots introduces a systematic error that simultaneously corrupts both the control loop (via incorrect Jacobian computation) and the state observation (via incorrect forward kinematics), degrading the robot from a fully observable Markov Decision Process (MDP) to a Partially Observable MDP (POMDP). This thesis addresses the challenge of maintaining robust manipulation performance under unknown encoder bias without requiring downtime for recalibration.

We first formalize the encoder bias problem as a POMDP, where the bias vector acts as an episode-level latent variable that renders the true joint state unobservable. Through observability analysis, we show that standard proprioceptive observations are insufficient to distinguish different bias conditions, and that augmenting the observation with an external end-effector position signal restores approximate observability—effectively reducing the POMDP back to an MDP that can be solved with standard reinforcement learning algorithms.

Building on this insight, we propose a two-component system: (1) a *robust task policy* trained with Reinforcement Learning from Prior Data (RLPD) under randomized encoder bias, which achieves 92–100% success rate across the full bias range $[0, 0.3]$ rad on a simulated pick-and-place task; and (2) a *backup safety policy* that protects human operators during human-in-the-loop training by performing active collision avoidance when a hand enters the shared workspace. Domain randomization on the backup policy bridges the sim-to-real gap for noisy hand detection.

Ablation studies confirm that the external position signal is necessary for bias-robust performance, validating the theoretical observability analysis. We further present a real-robot deployment architecture for the Franka Panda, including a dual-injection-point fault injection scheme that faithfully reproduces the encoder bias causal chain on physical hardware.

Keywords: POMDP; reinforcement learning; fault tolerance; encoder bias; robot manipulation

目录

摘要	i
Abstract	iii
第一章 绪论	1
1.1 研究背景与动机	1
1.2 问题陈述	1
1.3 论文贡献	1
1.4 论文组织结构	1
第二章 相关工作	3
2.1 机器人容错控制	3
2.2 POMDP 求解方法	3
2.3 鲁棒强化学习	3
2.4 人在回路强化学习	3
2.5 安全强化学习与避障	3
第三章 编码器偏差建模与 POMDP 形式化	5
3.1 工业机器人编码器校准偏差	5
3.2 因果链：一源三效应	7
3.2.1 效应 1：初始位置偏移	7
3.2.2 效应 2：控制偏差	8
3.2.3 效应 3：感知偏差	9
3.2.4 因果链总结	9
3.3 POMDP 形式化	10
3.3.1 无偏差情况下的 MDP 基准	10
3.3.2 有编码器偏差的 POMDP	11
3.3.3 隐变量 $\mathbf{b}$ 的 episode 级静态性	11
3.4 可观测性分析	12
3.4.1 命题 1：基础观测下的不可辨识性	12

3.4.2	命题 2: 观测增强恢复可辨识性	12
3.4.3	可辨识性 $\neq$ 可求解性	13
3.4.4	讨论: 噪声、构型信息与实验对应	15
3.5	仿真实现与等价性分析	15
3.5.1	故障注入的充分条件	16
3.5.2	MuJoCo 中的具体实现	16
3.5.3	外部传感器仿真	18
3.5.4	仿真与真实的主要差距	18
第四章	任务策略: 方法设计与共享网络架构	19
4.1	方法设计动机	19
4.2	观测空间设计	20
4.2.1	观测向量构成	20
4.2.2	信息通路	21
4.2.3	为何保留被污染的本体感觉	21
4.2.4	图像观测与 TCP 定位的通用化处理	22
4.3	随机偏差训练	23
4.4	网络架构与训练目标	23
4.5	奖励设计	27
第五章	仿真: 策略训练与可观测性验证	29
5.1	章节引言: 仿真侧范式与本章组织	29
5.2	任务策略仿真训练 (HIL-SERL)	29
5.3	备份策略仿真训练 (SAC + DR)	31
5.3.1	问题定义与部署场景	31
5.3.2	训练范式选择	32
5.3.3	场景、观测与运动模式	33
5.3.4	奖励函数设计演化	34
5.3.5	V3 $\rightarrow$ V3b 几何升级: 从单球到 5 球全臂	35
5.3.6	训练协议与域随机化	36
5.4	仿真实验与分析	37
5.4.1	实验设置	38
5.4.2	H1: 编码器偏差退化基线	38
5.4.3	H2 + H3: 固定 vs 随机偏差训练	38
5.4.4	观测空间消融: 从 18D 到 24D	39
5.4.5	Backup S1 V3b 主存活率	40
5.4.6	Backup 偏差鲁棒性 zero-shot	40
5.4.7	Reward V1 / V2 / V3 演化训练曲线	40

5.4.8 Backup S2 多障碍场景扩展	41
5.5 仿真到真机的桥接	41
第六章 真机：模仿部署与端到端验证	43
6.1 占位 (C3 重组中)	43
第七章 真机部署与验证	45
7.1 硬件架构	45
7.2 真机故障注入方案	45
7.3 OSC 与阻抗控制的等价性	45
7.4 外部定位方案	45
7.5 实验结果	45
第八章 总结与展望	47
8.1 工作总结	47
8.2 局限性	47
8.3 未来工作	47
参考文献	49

插图

3.1	理想情况下的控制与观测数据流	8
3.2	编码器偏差的因果链	10
3.3	可辨识性的几何示意。横轴 $\mathbf{q}_{\text{true}}$ / 纵轴 $\mathbf{b}$ 为抽象一维表示。(a) 仅依赖基础观测时，所有满足 $\mathbf{q}_{\text{true}} + \mathbf{b} = \mathbf{c}$ (红色虚线) 的 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 对都产生相同的观测 $\mathbf{o}$, δ 方向上的平移对称性使原问题不可辨识。(b) 引入独立外部位置观测后，由式 (3.19), $\mathbf{q}_{\text{true}}$ 被锁定到 $\text{FK}^{-1}(\mathbf{o}_{\text{real}})$ (蓝色实线); 该约束与等价线的交点唯一 (绿色圆点), 即 Proposition 3.2 给出的可辨识解。 $\sigma > 0$ 时蓝线变为有限宽度的”带”, 唯一性退化为后验上的最大似然估计——这正是第 3.4.3 节中”平均性补偿”的几何来源。	14
4.1	25 维观测空间的信息通路示意。编码器路径 (左, 18D) 中的关节角与由其导出的 TCP 位置被偏差 $\mathbf{b}$ 污染, 关节速度与夹爪开度不受影响; 外部观测路径 (右, 7D) 包含独立 TCP 与人手信息, 全部与编码器解耦。两路信号在策略网络处汇合, 策略原则上可通过 $\mathbf{q} + \mathbf{b}$ 与 $\mathbf{o}_{\text{real}}$ 之间的不一致隐式恢复 $\mathbf{b}$ 。	22
4.2	任务策略的网络架构。三路输入 (仿真 25 维 / 真机 14 维状态 + 前视、腕部 128×128 RGB) 分别经各自的编码器处理后, 按通道拼接为 768 维的共享 feature $\mathbf{h}$; 三个头共享 $\mathbf{h}$ 作为输入但输出与训练损失各异——连续 Actor 产生 6 维 Cartesian 末端动作、Twin Critic 输出两个标量 Q 值 (取最小以抑制高估)、离散 Gripper Critic 输出 3 维 Q 值选择夹爪动作。DINOv3-S 主干在训练中保持冻结, 只更新其后的投影层、状态编码器与三个头。仿真 HIL-SERL 训练四个头的损失, 真机 BC 阶段仅训练连续 Actor (critic 与温度参数作为 ckpt schema 占位)。	24
5.1	HIL-SERL 的 Actor-Learner 分布式架构。Actor 负责与环境交互、接收 HIL 干预、写入在线缓冲区; Learner 持有缓冲区与优化器, 负责混合采样、SAC 更新并回推权重。两侧通过 gRPC 通讯, 环境采样与梯度更新完全解耦。	30

- 5.2 部署场景示意（俯视）。机械臂把方块从 Zone A 搬运到 Zone B 的目标板;Zone B 同时是人机协同区，工人偶尔从 Zone C 一侧伸手进入。当人手进入 Zone B 并距 TCP 小于阈值时，备份避让策略接管、保证机械臂主动闪避。（示意图，后期精修。） 31

表格

3.1	编码器校准偏差的五种来源及其特征	6
4.1	从第 三 章 的理论分析与现实约束到本章方法设计的映射	20
4.2	任务策略的 25 维状态观测构成	21
4.3	任务策略训练超参数（仿真 HIL-SERL 与真机 BC + HG-DAGger 对照； “—” 表示不适用）	26
5.1	备份策略训练中的四种障碍物运动模式	34
5.2	V3 奖励下典型场景的总期望回报 ($\gamma = 1.0$, 10 步 episode)	35
5.3	备份策略相对任务策略的关键超参数差异	37
5.4	备份策略训练中的域随机化参数	37
5.5	备份策略的 Sim-to-Real 差距分析	37
5.6	H1: 无偏差策略在不同 J5 偏差下的退化	38
5.7	H2 + H3: 三种策略在偏差扫描下的成功率对比	39
5.8	观测空间消融: 理论预测与实测的一一对照	39

第一章 绪论

1.1 研究背景与动机

1.2 问题陈述

1.3 论文贡献

1.4 论文组织结构

第二章 相关工作

2.1 机器人容错控制

2.2 POMDP 求解方法

2.3 鲁棒强化学习

2.4 人在回路强化学习

2.5 安全强化学习与避障

第三章 编码器偏差建模与 POMDP 形式化

3.1 工业机器人编码器校准偏差

串联型工业机器人的闭环控制依赖于每个关节的角度反馈。无论是低层的关节伺服控制器、笛卡尔空间的阻抗/导纳控制器，还是上层任务规划，都需要以关节编码器测得的角度 $\mathbf{q}_{\text{measured}}$ 作为输入，并通过正运动学（Forward Kinematics, FK）与雅可比矩阵 $\mathbf{J}(\mathbf{q})$ 建立关节空间与任务空间的联系 [17]。在理想情况下，编码器读数等于真实关节角度（ $\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}}$ ），此时控制器的力矩计算与观测模块的末端位姿估计均建立在准确的状态信息之上。然而，真实工业环境下该假设常常被破坏：编码器与真实关节之间可能存在一个系统性偏差 $\mathbf{b} \in \mathbb{R}^7$ ，使得

$$\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}} + \mathbf{b}. \quad (3.1)$$

由于机器人的控制与观测共享同一个编码器读数，偏差 $\mathbf{b}$ 会同时污染控制回路与状态观测，这一点将在第 3.2 节 中详细分析。

编码器偏差的五种来源

编码器校准偏差在工业实践中可由多种物理机制导致。ISO 9283:1998 [8] 为工业机器人位姿准确度、重复性和漂移等性能特征提供了标准化测试方法，其中明确列出了位姿漂移和交换性等指标，反映出上述偏差在真实部署中的普遍性。以下依时间尺度与物理机制对这些来源进行分类，并给出可从现有文献或工程实践中获得的代表性量级。

1. **出厂标定残差**：即使经过严格的运动学参数辨识，受限于标定设备精度与运动学模型的简化，出厂标定后的关节零位仍会残留微小偏差。作为具体参考，Kana 等 [10] 在 Kinova Gen3 七自由度机械臂上进行运动学再标定，报告的七个关节角度零偏差量分布于区间 $[-0.0084, 0.0088]$ rad，大致对应 0.5° 量级。这是本文五种来源中唯一具有直接实证量级支撑的一类。
2. **温度漂移**：机械臂长时间运行后，电机、减速器与连杆因发热产生热膨胀，引起末端位姿缓慢漂移。Gong 等 [4] 通过激光跟踪仪的逆标定建模了工业机器人中的几

何、刚度与时变热误差三者耦合的影响；Vocetka 等 [21] 进一步量化了漂移对重复性的影响并给出补偿方法。现有文献通常将温漂效应报告为任务空间的位姿误差（毫米量级），回推至关节空间则大约处于 10^{-3} – 10^{-2} rad 范围，数量级上远小于后述几类故障。

3. **更换电机或减速器未重新标定**：维护作业中若未对替换部件进行零位重标（例如未执行 KUKA 的”mastering”或 Franka 的零位复位流程），将引入固定偏差。例如在典型的谐波减速器（减速比 100–160）中，一个输入齿的错位即可在输出端造成约 0.04 rad 的偏差，而耦合器重装或皮带张紧变化的影响则可进一步叠加。由于这类偏差取决于具体维护操作，学术文献中缺乏统计报告，本文将其视为工程估计而非实证量级，可能的幅值范围约为 0.05–0.3 rad 量级。
4. **碰撞后编码器错位**：意外碰撞可能导致关节编码器、谐波减速器或耦合器相对位置突变，产生突发性偏差。Haddadin 等 [6] 对机器人碰撞的检测、隔离与辨识进行了系统综述，但该领域文献主要关注检测和恢复而非碰撞后残留偏差的量级统计。本文将碰撞导致的偏差同样视为设计包络，可能的幅值范围视碰撞严重程度从 0.1 rad 延展至更大量级。
5. **编码器噪声与电磁干扰**：现代光学编码器通过差分线驱与屏蔽设计已对电磁干扰有较强抑制。残余的测量噪声（含量化噪声）在典型 17–20 位绝对编码器上约为 10^{-3} rad 量级，呈零均值随机性，与前四种系统性偏差在统计特征上本质不同。

表 3.1 汇总了上述五种偏差来源的关键特征，并在表中以实证量级与工程估计两种类别加以区分，以明确各来源在文献支撑上的差异。

表 3.1: 编码器校准偏差的五种来源及其特征

来源	时间特征	类别	代表量级 (rad)	本文覆盖
出厂标定残差	固定	实证量级 [10]	$\sim 10^{-3}$ – 10^{-2}	✓
温度漂移	缓变	实证量级 [4, 21]	$\sim 10^{-3}$ – 10^{-2}	×
更换部件未重标	固定	工程估计	$\sim 10^{-1}$	✓
碰撞后错位	突变	设计包络 [6]	$\gtrsim 10^{-1}$	✓
编码器噪声/EMI	随机	量化 + 噪声	$\sim 10^{-3}$	×

本文的研究范围

在上述五种来源中，本文聚焦于 **episode 内恒定的偏差**（即来源 1、3、4），涵盖两种实验设置：固定偏差在所有 episode 中使用同一个 $\mathbf{b}$ ，对应单一已知故障；随机偏差则在每个 episode 开始时从分布 $P(\mathbf{b})$ 采样，对应未知故障量级的分布。两者的共同特征是 $\mathbf{b}$ 在 episode 内不变，均可建模为 POMDP 的静态隐变量（详见第 3.3 节）；而

温度漂移与电磁干扰需要时变隐状态，属于本质不同的 POMDP 结构，留作未来工作。后续实验中，偏差对每个关节独立采样 $b_i \sim \mathcal{U}[0, 0.25 \text{ rad}]$ ($i = 1, \dots, 7$, 约 14.3°)，有意超过出厂标定残差的典型量级（表 3.1），以覆盖维护疏漏与碰撞后错位等更严重的故障场景。

针对此类偏差，现有方案如停机重新标定 [4, 10] 或传统容错控制框架 (FDI/FTC) [2] 均存在明显局限——前者需要中断生产，后者依赖明确的故障模型且以“保持稳定”而非“完成任务”为目标，相关讨论详见第二章。本文采取不同的路径：与其事后检测或切换，不如让策略在训练阶段就见过各种偏差，从而学会在线适应未知的校准偏差。后续章节将在理论与方法两个层面展开——Sections 3.2 to 3.4 刻画偏差对控制问题结构的本质影响，第四章给出具体的策略学习方法。

3.2 因果链：一源三效应

在第 3.1 节中，我们将编码器偏差形式化为一个关节空间的加性误差 $\mathbf{b}$ ，使得 $\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}} + \mathbf{b}$ （见式 (3.1)）。这一定义本身只刻画了“什么是偏差”，但尚未回答一个更关键的问题：一个编码器偏差如何在机器人闭环控制系统中传播，最终影响任务执行？

回答这个问题是后续 POMDP 建模（第 3.3 节）的前提。本节将证明：**单一编码器偏差 $\mathbf{b}$ 会沿三条相互独立的路径产生三个可观测的效应，但这三个效应并非独立故障，而是同一隐变量在不同模块上的投影。**

要理解偏差如何传播，首先梳理无偏差情况下 Franka Panda 等串联机械臂的标准控制与观测结构 [17]。如图 3.1 所示，机器人在一个控制周期内有三个模块显式依赖同一个编码器读数 $\mathbf{q}_{\text{measured}}$ ：**底层关节 PD 控制器**（对 Franka Panda 而言运行于其 FCI 的 1 kHz 实时循环中 [3, 7]）跟踪期望关节角；**任务层 OSC 控制器**通过 $\mathbf{J}(\mathbf{q}_{\text{measured}})$ 与 $\mathbf{FK}(\mathbf{q}_{\text{measured}})$ 将任务空间误差映射为关节力矩；**观测模块**向上层策略返回 $\mathbf{q}_{\text{measured}}$ 与 $\mathbf{FK}(\mathbf{q}_{\text{measured}})$ 。三个模块共享同一个编码器读数——这正是一个 $\mathbf{b}$ 能够同时污染控制与观测的结构性原因¹。

3.2.1 效应 1：初始位置偏移

在 episode 开始时，上层通常指令机器人移动到一个预设的初始位姿 $\mathbf{q}_{\text{home}}$ 。Franka Panda 的底层关节伺服可近似建模为具有重力补偿的 PD 跟踪控制器 [17]：

$$\boldsymbol{\tau}_{\text{joint}} = \mathbf{K}_p(\mathbf{q}_{\text{target}} - \mathbf{q}_{\text{measured}}) + \mathbf{K}_d(\dot{\mathbf{q}}_{\text{target}} - \dot{\mathbf{q}}_{\text{measured}}) + \mathbf{g}(\mathbf{q}_{\text{measured}}), \quad (3.2)$$

其中 $\mathbf{K}_p, \mathbf{K}_d \succ 0$ 为刚度与阻尼矩阵， $\mathbf{g}(\cdot)$ 为重力补偿项。到 home 位姿的场景下 $\mathbf{q}_{\text{target}} = \mathbf{q}_{\text{home}}$ 为常量，因此 $\dot{\mathbf{q}}_{\text{target}} = \mathbf{0}$ ；当系统到达稳态时进一步有 $\dot{\mathbf{q}}_{\text{measured}} = \mathbf{0}$ ，且

¹本节假设真机使用由底层实时控制器执行的关节伺服；仿真环境中该底层循环通过直接设置初始关节位置进行简化，具体实现详见第 3.5 节。




图 3.1: 理想情况下 Franka Panda 的控制与观测数据流。三个下游模块（底层关节 PD、任务层 OSC、观测模块）均以同一个编码器读数 $\mathbf{q}_{\text{measured}}$ 作为输入。这一共享依赖是编码器偏差能够同时污染控制与观测的结构性原因。（示意图，后期将替换为精修版本。）

被动力矩与重力补偿抵消，(3.2) 式化为

$$\mathbf{K}_p(\mathbf{q}_{\text{target}} - \mathbf{q}_{\text{measured}}) = \mathbf{0} \implies \mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{target}}. \quad (3.3)$$

这正是 PD 控制器的基本性质：在稳态下测量值等于期望值。然而 PD 控制器的反馈回路闭合于编码器读数，对物理世界中的真实关节角是不可见的。将式 (3.1) 代入式 (3.3)，得到：

$$\mathbf{q}_{\text{true}} + \mathbf{b} = \mathbf{q}_{\text{home}} \implies \boxed{\mathbf{q}_{\text{true}} = \mathbf{q}_{\text{home}} - \mathbf{b}.} \quad (3.4)$$

物理含义 机器人在数据层面认为自己已经到达 $\mathbf{q}_{\text{home}}$ ，但物理上所有关节均存在一个大小为 $\mathbf{b}$ 、方向与偏差相反的偏移。这一效应是“偏差从数字世界投射到物理世界”的第一步：尚未有任何控制指令被错误执行，系统却已经身处一个错误的物理状态。后续所有运动都将从这个被污染的起点出发。

3.2.2 效应 2：控制偏差

在 episode 进行过程中，任务层 OSC 控制器将期望末端位姿 $\mathbf{x}_{\text{target}}$ 转换为关节力矩。标准 OSC 控制律 [15, 17] 形式为：

$$\boldsymbol{\tau}_{\text{osc}}(\mathbf{q}) = \mathbf{J}(\mathbf{q})^\top \boldsymbol{\Lambda}(\mathbf{q}) [\mathbf{K}_x \mathbf{e}_x(\mathbf{q}) + \mathbf{K}_v \dot{\mathbf{e}}_x(\mathbf{q})] + \boldsymbol{\tau}_{\text{null}}(\mathbf{q}) + \mathbf{g}(\mathbf{q}), \quad (3.5)$$

其中 $\mathbf{e}_x(\mathbf{q}) = \mathbf{x}_{\text{target}} - \text{FK}(\mathbf{q})$ 为任务空间位置误差， $\boldsymbol{\Lambda}(\mathbf{q}) = (\mathbf{J}(\mathbf{q})\mathbf{M}^{-1}(\mathbf{q})\mathbf{J}(\mathbf{q})^\top)^{-1}$ 为任务空间惯性矩阵， $\boldsymbol{\tau}_{\text{null}}$ 为零空间项， $\mathbf{g}$ 为重力补偿。控制律显式依赖五个以 $\mathbf{q}$ 为自变量的函数： $\mathbf{J}, \boldsymbol{\Lambda}, \text{FK}, \boldsymbol{\tau}_{\text{null}}, \mathbf{g}$ 。

在存在偏差时控制器读到的是 $\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}} + \mathbf{b}$, 因此实际施加的力矩为 $\boldsymbol{\tau}^{\text{biased}} = \boldsymbol{\tau}_{\text{osc}}(\mathbf{q}_{\text{true}} + \mathbf{b})$, 与理想力矩 $\boldsymbol{\tau}_{\text{osc}}(\mathbf{q}_{\text{true}})$ 存在差值 $\Delta\boldsymbol{\tau}(\mathbf{b})$ 。对小偏差做一阶展开:

$$\Delta\boldsymbol{\tau}(\mathbf{b}) = \boldsymbol{\tau}_{\text{osc}}(\mathbf{q}_{\text{true}} + \mathbf{b}) - \boldsymbol{\tau}_{\text{osc}}(\mathbf{q}_{\text{true}}) \approx \left. \frac{\partial \boldsymbol{\tau}_{\text{osc}}}{\partial \mathbf{q}} \right|_{\mathbf{q}_{\text{true}}} \mathbf{b}. \quad (3.6)$$

其中 $\partial \boldsymbol{\tau}_{\text{osc}} / \partial \mathbf{q}$ 同时包含 $\mathbf{J}$ 、FK、 $\boldsymbol{\Lambda}$ 对关节角的变化, 对任何非平凡运动学结构均不为零, 因此:

$$\forall \mathbf{b} \neq \mathbf{0}: \quad \Delta\boldsymbol{\tau}(\mathbf{b}) \neq \mathbf{0}. \quad (3.7)$$

物理含义 任意非零的编码器偏差都会使控制器输出一个在大小与方向上均偏离理想值的关节力矩; 一阶展开式 (3.6) 表明力矩偏差的幅度与 $\mathbf{b}$ 近似成线性, 方向由 OSC 控制律对 $\mathbf{q}$ 的梯度决定。该效应源自 $\mathbf{J}$ 与 FK 在不同关节构型下的差异而非任何加性噪声, 因此即使 $\mathbf{b}$ 在 episode 内恒定, 力矩偏差也会在整个轨迹上持续存在。

3.2.3 效应 3: 感知偏差

上层策略 π 依据观测函数所返回的状态 $\mathbf{o}$ 决定下一步动作。以 Franka Panda 的典型任务为例, 观测中至少包含以下分量:

$$\mathbf{o} = (\mathbf{q}_{\text{measured}}, \dot{\mathbf{q}}_{\text{measured}}, \mathbf{x}_{\text{ee}}^{\text{FK}}, \dots), \quad (3.8)$$

其中 $\mathbf{x}_{\text{ee}}^{\text{FK}} = \text{FK}(\mathbf{q}_{\text{measured}})$ 为末端执行器位置的运动学估计。将式 (3.1) 代入:

$$\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}} + \mathbf{b}, \quad (3.9)$$

$$\mathbf{x}_{\text{ee}}^{\text{FK}} = \text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b}) \neq \text{FK}(\mathbf{q}_{\text{true}}). \quad (3.10)$$

注意到 $\dot{\mathbf{q}}_{\text{measured}} = \dot{\mathbf{q}}_{\text{true}}$: 因为 $\mathbf{b}$ 在一个 episode 内恒定, 对时间求导后消失。因此在 episode 内, 感知偏差仅作用于位置类观测 (关节角和末端位置), 不影响速度类观测。

物理含义 策略所“看到”的机器人状态在位置维度上系统性地撒谎。两个位置类观测—— $\mathbf{q}_{\text{measured}}$ 与 $\mathbf{x}_{\text{ee}}^{\text{FK}}$ ——表面是两条独立信息源, 实际共享同一个被污染的底层变量, 因此策略无法通过比较它们来检测偏差 ($\mathbf{x}_{\text{ee}}^{\text{FK}}$ 就是 $\mathbf{q}_{\text{measured}}$ 的正运动学, 两者之间的任何“一致性检查”都恒为真)。这一观察将在第 3.4 节的可观测性分析中扮演核心角色。

3.2.4 因果链总结

三个效应虽然经由不同路径 (PD 反馈、OSC 雅可比/FK、观测函数) 产生, 但全部源自同一个关节空间变量 $\mathbf{b}$ ——这正是第 3.3 节把 $\mathbf{b}$ 建模为单一 episode 级隐变量的直接依据。图 3.2 以图示方式总结这一耦合结构。




图 3.2: 编码器偏差 $\mathbf{b}$ 的因果链: “一源三效应”结构。单个关节空间隐变量 $\mathbf{b}$ 通过三条结构上相互独立的路径——底层 PD 控制器的反馈回路、OSC 控制律中的雅可比与 FK、以及观测函数——同时产生三个可观测的效应。三个效应并非独立故障, 而是同一隐变量在不同模块上的投影。(示意图, 后期将替换为精修版本。)

3.3 POMDP 形式化

第 3.2 节从物理层面刻画了编码器偏差的传播路径。本节将这一物理故事翻译成强化学习领域的标准语言: 先回顾无偏差情况下的 MDP 基准, 再引入偏差后的 POMDP 模型, 并重点分析隐变量 $\mathbf{b}$ 的 episode 级静态性质——这一性质是本文方法论的核心前提, 也是后续第 3.4 节可观测性分析的出发点。

3.3.1 无偏差情况下的 MDP 基准

在没有编码器偏差的理想情况下, 机器人操作任务可以建模为一个离散时间马尔可夫决策过程 [19]

$$\mathcal{M}_0 = (\mathcal{S}^{\text{phys}}, \mathcal{A}, T_{\text{phys}}, R, \gamma), \quad (3.11)$$

其中物理状态空间 $\mathcal{S}^{\text{phys}}$ 的元素记作 $\mathbf{s}^{\text{phys}}$, 包含机器人的真实运动学状态与任务相关的环境变量:

$$\mathbf{s}^{\text{phys}} = (\mathbf{q}, \dot{\mathbf{q}}, g, \mathbf{x}_{\text{ee}}, \mathbf{x}_{\text{obj}}), \quad (3.12)$$

即 7 维关节角、关节速度、夹爪开度、末端位置与任务目标物的位置。动作空间 $\mathcal{A} \subseteq \mathbb{R}^7$ 为上层策略可发出的控制指令 (具体形式将在第四章中定义); $T_{\text{phys}}(\mathbf{s}^{\text{phys}'} | \mathbf{s}^{\text{phys}}, \mathbf{a})$ 为由物理仿真器决定的状态转移核; R 为稀疏的任务成功奖励; $\gamma \in (0, 1)$ 为折扣因子。在此基准下, 系统是完全可观测的, 即观测 $\mathbf{o} = \mathbf{s}^{\text{phys}}$, 最优策略取形式 $\pi^*(\mathbf{a} | \mathbf{s}^{\text{phys}})$ 。

3.3.2 有编码器偏差的 POMDP

引入编码器偏差 $\mathbf{b}$ 后，Sections 3.2.1 to 3.2.3 告诉我们：真实关节角 $\mathbf{q}_{\text{true}}$ 、真实末端位置 $\mathbf{x}_{\text{ee,true}}$ 以及偏差 $\mathbf{b}$ 本身对智能体均不可见。这一信息结构上的退化正是部分可观测马尔可夫决策过程 (POMDP) [9] 所描述的情形。我们将带偏差的问题形式化为七元组

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, T, R, \Omega, O, \gamma). \quad (3.13)$$

状态空间 在基准 MDP 的物理状态之上再附加一个偏差分量：

$$\mathbf{s} = (\mathbf{s}^{\text{phys}}, \mathbf{b}), \quad \mathbf{s}^{\text{phys}} = (\mathbf{q}_{\text{true}}, \dot{\mathbf{q}}, g, \mathbf{x}_{\text{ee,true}}, \mathbf{x}_{\text{obj}}), \quad (3.14)$$

其中 $\mathbf{q}_{\text{true}}$ 与 $\mathbf{x}_{\text{ee,true}}$ 是物理上的真实值， $\mathbf{b} \in \mathbb{R}^7$ 是 episode 级的隐变量。

观测空间与观测函数 观测空间 Ω 由第 3.2.3 节 给出的感知结构决定。观测函数 O 为确定性映射²

$$\mathbf{o} = O(\mathbf{s}) = (\underbrace{\mathbf{q}_{\text{true}} + \mathbf{b}}_{\text{污染}}, \dot{\mathbf{q}}, g, \underbrace{\text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b})}_{\text{污染}}, \mathbf{x}_{\text{obj}}). \quad (3.15)$$

注意观测中的两个位置类分量——关节角与末端位置——均被同一个 $\mathbf{b}$ 污染；速度类与外部感知类分量 ($\dot{\mathbf{q}}$ 、 g 、 $\mathbf{x}_{\text{obj}}$) 不受影响。奖励 R 与折扣因子 γ 与基准 MDP 一致；转移核 T 的具体形式将在下一小节推导。由于 $\mathbf{o} \neq \mathbf{s}$ ，策略只能依赖部分观测，取形式 $\pi(\mathbf{a} | \mathbf{o})$ 。

3.3.3 隐变量 $\mathbf{b}$ 的 episode 级静态性

本节的核心观察是： $\mathbf{b}$ 不是经典 POMDP 中逐步演化的隐状态，而是 episode 级的常量—— $\mathbf{b}$ 在每个 episode 开始时按分布 $P(\mathbf{b})$ 采样一次，之后在 episode 内保持不变，智能体的任何动作都无法改变其值。这与经典 POMDP 的时变隐状态有本质区别：后者要求智能体通过时序观测追踪信念 (belief)，而 $\mathbf{b}$ 作为 episode 级“环境参数”则不需要时序跟踪。这一静态性带来两个对本文方法论至关重要的推论：(1) 偏差信息在整个 *episode* 内一致，因此原则上不需要循环记忆机制，合适的观测增强即可将 POMDP 在信息结构层面近似还原为 MDP（见第 3.4 节）；(2) 策略最优性是在 $P(\mathbf{b})$ 分布上定义的，

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\mathbf{b} \sim P(\mathbf{b}), \tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t R(\mathbf{s}_t, \mathbf{a}_t) \right], \quad (3.16)$$

即策略必须在偏差分布上取得期望最优，这直接激励了本文的随机偏差训练（见第 4.3 节）。

²此处仅纳入受偏差影响的基础观测量以聚焦理论分析；关于引入外部末端位置观测 $\mathbf{x}_{\text{ee,true}} + \epsilon$ 的扩展观测空间，将在第 3.4 节 中讨论。

3.4 可观测性分析

第 3.3 节 已将带偏差的机器人操作建模为 POMDP，但”建模”与”求解”之间还存在一个关键的理论缺口：策略 $\pi(\mathbf{a} | \mathbf{o})$ 只能依赖单步观测 $\mathbf{o}$ 做决策，那么从一个 $\mathbf{o}$ 出发，能否唯一地反推出真实物理状态 $\mathbf{q}_{\text{true}}$ 和隐变量 $\mathbf{b}$ ？这个问题的答案决定了 POMDP 在信息结构上是否”可解”。

本节给出两条互补的结论：**命题 3.1** 证明只依靠式 (3.15) 给出的基础观测无法区分不同的 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ ；**命题 3.2** 则证明若进一步引入一个独立于编码器的外部位置观测， $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 可被唯一恢复。这两个命题从理论上精确预测了第 5.4.4 节 中观测空间消融实验的成功与失败。

3.4.1 命题 1：基础观测下的不可辨识性

命题 3.1 (基础观测下的不可辨识性). 设 POMDP 的观测函数 O 由式 (3.15) 给出：

$$\mathbf{o} = O(\mathbf{s}) = (\mathbf{q}_{\text{true}} + \mathbf{b}, \dot{\mathbf{q}}, g, FK(\mathbf{q}_{\text{true}} + \mathbf{b}), \mathbf{x}_{\text{obj}}).$$

对任意固定观测 $\mathbf{o}$ ，存在无穷多 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 对产生该观测。因此， O 在 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 上不是单射， $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 不可由 $\mathbf{o}$ 唯一确定。

证明. 考察观测 $\mathbf{o}$ 中与 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 相关的两个分量：关节读数 $\mathbf{q}_{\text{true}} + \mathbf{b}$ 与末端估计 $FK(\mathbf{q}_{\text{true}} + \mathbf{b})$ 。两者都仅依赖于和 $\mathbf{q}_{\text{true}} + \mathbf{b}$ ，而不单独依赖 $\mathbf{q}_{\text{true}}$ 或 $\mathbf{b}$ 。

取任意 $\delta \in \mathbb{R}^7$ ，构造另一对 $(\tilde{\mathbf{q}}, \tilde{\mathbf{b}}) = (\mathbf{q}_{\text{true}} - \delta, \mathbf{b} + \delta)$ ，则

$$\tilde{\mathbf{q}} + \tilde{\mathbf{b}} = (\mathbf{q}_{\text{true}} - \delta) + (\mathbf{b} + \delta) = \mathbf{q}_{\text{true}} + \mathbf{b},$$

因此 $FK(\tilde{\mathbf{q}} + \tilde{\mathbf{b}}) = FK(\mathbf{q}_{\text{true}} + \mathbf{b})$ 。其余观测分量 $(\dot{\mathbf{q}}, g, \mathbf{x}_{\text{obj}})$ 不依赖于 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ ，因此在变换下保持不变。

综上，对任意 δ ，新旧两对 $(\mathbf{q}, \mathbf{b})$ 产生完全相同的观测 $\mathbf{o}$ 。由 δ 的任意性，存在无穷多 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 对与给定 $\mathbf{o}$ 相容。□

命题 3.1 表明 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 之间存在一个方向任意的平移对称性：沿着 δ 方向同时调整真实关节角和偏差，观测一字不差。其根本原因在于第 3.2.3 节 所揭示的事实——两个位置类观测分量虽然看似独立，实际上共享被污染的 $\mathbf{q}_{\text{measured}}$ ，两者之间恒为自治，无法提供额外的辨识信息。因此，任何仅依赖单步基础观测的策略在原则上都无法区分不同的 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ ，从而无法对不同的偏差做出有针对性的响应。

3.4.2 命题 2：观测增强恢复可辨识性

命题 3.1 的症结在于所有位置类观测都经过同一个被污染的编码器通道。要打破平移对称性，必须引入一个独立于编码器的位置观测。一个自然的选择是外部定位系统

——例如 OptiTrack 动捕、ArUco 视觉标记配合 Intel RealSense D455 等——它们不依赖机器人自身的关节编码器，直接测量末端执行器在世界坐标系下的真实位置。这类测量可以统一建模为

$$\mathbf{o}_{\text{real}} = \text{FK}(\mathbf{q}_{\text{true}}) + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_3), \quad (3.17)$$

其中 σ 表征定位系统的精度。将这一观测分量附加到基础观测函数 O 中，得到增强观测空间 Ω' 与增强观测函数：

$$\mathbf{o}' = O'(s) = \underbrace{(\mathbf{q}_{\text{true}} + \mathbf{b}, \dot{\mathbf{q}}, g, \text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b}), \mathbf{x}_{\text{obj}}, \mathbf{o}_{\text{real}})}_{\mathbf{o}}. \quad (3.18)$$

命题 3.2 (增强观测下的可辨识性). 设增强观测函数 O' 由式 (3.18) 给出，且外部定位无噪声 ($\boldsymbol{\epsilon} = \mathbf{0}$)。若 FK 在当前构型 $\mathbf{q}_{\text{true}}$ 附近的一个邻域内是单射³，则 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 可由 $\mathbf{o}'$ 唯一确定。

证明. 在 $\boldsymbol{\epsilon} = \mathbf{0}$ 的条件下，由式 (3.17)， $\mathbf{o}_{\text{real}} = \text{FK}(\mathbf{q}_{\text{true}})$ 。根据 FK 局部单射的假设，存在一个局部反函数 FK^{-1} 使得

$$\mathbf{q}_{\text{true}} = \text{FK}^{-1}(\mathbf{o}_{\text{real}}). \quad (3.19)$$

既然 $\mathbf{q}_{\text{true}}$ 已知，又因为 $\mathbf{o}$ 中包含分量 $\mathbf{q}_{\text{true}} + \mathbf{b}$ ，便可以直接解出

$$\mathbf{b} = (\mathbf{q}_{\text{true}} + \mathbf{b}) - \mathbf{q}_{\text{true}}. \quad (3.20)$$

因此 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 由 $\mathbf{o}'$ 唯一确定。 $\square$

与命题3.1 相比，命题3.2 的关键不同在于： $\mathbf{o}_{\text{real}}$ 绕开了被污染的编码器通道，直接提供了一个仅依赖 $\mathbf{q}_{\text{true}}$ （而非 $\mathbf{q}_{\text{true}} + \mathbf{b}$ ）的”独立观测”，从而打破了命题3.1 证明中使用的平移对称性。在信息论视角下， $\mathbf{o}_{\text{real}}$ 与已有的位置类观测线性无关，恰好补足了原先缺失的一维辨识方向。其几何直觉如图 3.3 所示。

3.4.3 可辨识性 $\neq$ 可求解性

命题3.2 是信息论层面的结论：增强观测 $\mathbf{o}'$ 在原则上能够区分不同的 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 。但这并不等同于”问题已回归无偏差情形”——偏差并未消失，它只是从不可见变成了可推断。第 3.2.2 节 所证明的控制偏差和第 3.2.1 节 的初始位置偏移仍然存在：POMDP 的物理转移核 T_{phys} 在引入 $\mathbf{o}_{\text{real}}$ 前后完全相同，观测增强改变的是信息结构而非动力学。

³对 Franka Panda 这样的 7-DoF 冗余机械臂， FK 在全局上不是单射（存在 1-DoF 零空间）。然而在实操区域内远离奇异构型时， FK 在局部具有单射性质；结合速度观测 $\dot{\mathbf{q}}$ 可进一步消除零空间歧义。本节的讨论在此假设下成立。




图 3.3: 可辨识性的几何示意。横轴 q_{true} / 纵轴 b 为抽象一维表示。(a) 仅依赖基础观测时, 所有满足 $q_{\text{true}} + b = c$ (红色虚线) 的 (q_{true}, b) 对都产生相同的观测 $\mathbf{o}$, δ 方向上的平移对称性使原问题不可辨识。(b) 引入独立外部位置观测后, 由式 (3.19), q_{true} 被锁定到 $\text{FK}^{-1}(\mathbf{o}_{\text{real}})$ (蓝色实线); 该约束与等价线的交点唯一 (绿色圆点), 即 Proposition 3.2 给出的可辨识解。 $\sigma > 0$ 时蓝线变为有限宽度的“带”, 唯一性退化为后验上的最大似然估计——这正是第 3.4.3 节中“平均性补偿”的几何来源。

因此, “POMDP 近似还原为 MDP” 的严格意义是: 存在一个作用于 $\mathbf{o}'$ 的策略族 $\pi(\mathbf{a} | \mathbf{o}')$, 其贝尔曼方程求解与原 POMDP 的最优策略一致; 这里的 MDP 状态里仍然包含 b , 最优策略是一个以 b 为条件的函数:

$$\pi^*(\mathbf{a} | \mathbf{o}') = \pi^*(\mathbf{a} | q_{\text{true}}, b). \quad (3.21)$$

对不同的 b , π^* 必须输出不同的补偿动作。在 $\epsilon > 0$ 的现实情形下, 由于噪声使得不同的 (q_{true}, b) 可能产生几乎相同的 $\mathbf{o}'$, 最优动作退化为观测条件下后验上的期望最优, 即一种“平均性补偿”——策略在与观测相容的所有偏差上输出一个折中动作。

这一分析带来两个对后续章节至关重要的启示。首先, 单一策略要覆盖整个 $P(b)$, 训练时必须暴露于偏差分布的多样性——仅在固定 b 下训练会导致“单点条件化”: 策略学到特定偏差下的补偿量, 在其他偏差 (尤其是 $b = \mathbf{0}$ 的无故障情形) 上过补偿。这正是第 4.3 节 随机偏差训练的理论依据。其次, 观测增强提供了训练的可行性但不保证充分性——能否将“信息上可辨识”转化为“实际能学到”还依赖数据分布、奖励密度和优化能力。第 5.4.3 节的固定偏差实验将提供直接的实证支持: 在所有关节固定 $b_i = 0.2\text{rad}$ 下训练的策略在零偏差测试中成功率显著低于随机偏差训练得到的策略, 正是单点条件化导致的过补偿现象 (具体数值见第 5.4.3 节)。

3.4.4 讨论：噪声、构型信息与实验对应

定位噪声的影响 命题3.2 假设 $\epsilon = 0$ 。在 $\sigma > 0$ 的实际情况下， $\mathbf{q}_{\text{true}}$ 和 $\mathbf{b}$ 只能被近似恢复： $\sigma \rightarrow 0$ 时辨识精度趋于完美； σ 增大时辨识误差相应增大；极端地，若 σ 大到使 $\mathbf{o}_{\text{real}}$ 的信噪比低于 $\mathbf{b}$ 本身的典型幅值，则外部观测失去作用，系统退化回命题3.1 描述的不可辨识情形。本文采用的 $\sigma = 5 \text{ mm}$ 对应于 ArUco 视觉标记配合 D455 深度相机在典型工作距离下的定位精度，在实践中既易于实现，又足以支撑第四章中策略对偏差的鲁棒响应。

为什么仍保留带偏差的本体感觉 带偏差的 $\mathbf{q}_{\text{measured}}$ 仍然编码了机械臂的关节构型——奇异性邻近度、关节限位裕度、7-DoF 冗余度中的零空间方向等——这些信息单凭三维的 $\mathbf{o}_{\text{real}}$ 无法提供，构成保留本体感觉通路的必要性。与之互补的设计层面理由（信息完整性与运行时容错）见第 4.2.3 节。

与消融实验的对应 本节两个命题并非纯粹的理论推演，它们直接预测了第 5.4.4 节中观测空间消融实验的结果。消融实验把第四章使用的完整 31 维观测与剔除独立外部 TCP $\mathbf{o}_{\text{real}}$ 的 28 维变体进行对照——前者对应命题3.2 的可辨识情形，策略在全偏差范围内应保持鲁棒；后者对应命题3.1 的不可辨识情形，预期策略性能在偏差下严重退化。这一对应既为本文的观测空间设计提供了可验证的理论依据，也反向印证了两个命题并非形式化游戏，而是对问题本质的准确刻画。

3.5 仿真实现与等价性分析

前四节的分析均在抽象层面展开：第 3.2 节 给出偏差在控制与观测中传播的物理因果链，第 3.3 节 将其形式化为 POMDP，第 3.4 节 分析了信息结构上的可辨识性。本节的任务则是将这些抽象结论落地——在基于 MuJoCo 的仿真环境中忠实地复现第 3.2 节所描述的三个效应，并严格论证仿真实现与原物理机制在相关观测量上等价。

为什么不能简单沿用 joint_state 注入 在 ROS 环境下，一种常见的故障注入做法是直接对 `/joint_states` 话题上发布的关节角度加入偏差 [14]。这在“控制器订阅 `/joint_states` 做反馈”的标准 ROS 架构中是简洁有效的，因为偏差一经进入话题，自然地传播到所有下游读取方。然而本文的仿真和真机均不符合这一前提：仿真中的 OSC 控制器直接从 MuJoCo 的 `data.qpos` 读取关节角度，根本没有 `/joint_states` 话题作为中介；真机上 hil-serl 架构的阻抗控制器则通过 `FrankaStateHandle` 的 C++ 直接内存访问读取机器人状态，同样绕过了 ROS topic 通信（详见第六章）。在这两种情形下，仅在 `/joint_states` 上注入偏差都无法影响控制器或观测模块——需要设计一个与底层数据流耦合方式解耦的等价注入方案。本节首先给出与具体实现无关的充分条件，再在此基础上描述 MuJoCo 下的具体实现。

3.5.1 故障注入的充分条件

命题 3.3 (故障注入的充分条件). 设某一故障注入实现满足以下两个条件:

- (C1) 控制条件: 在控制律每次计算关节力矩时, 所使用的关节角度取值等于 $\mathbf{q}_{true} + \mathbf{b}$;
- (C2) 观测条件: 在观测模块每次返回状态时, 关节角分量等于 $\mathbf{q}_{true} + \mathbf{b}$, 末端位姿分量等于 $FK(\mathbf{q}_{true} + \mathbf{b})$ 。

则该实现忠实地复现第 3.2 节 所定义三个效应——初始位置偏移、控制偏差与感知偏差。

证明. 效应 2 (控制偏差): 第 3.2.2 节 定义下的偏差力矩为 $\boldsymbol{\tau}^{biased} = \boldsymbol{\tau}_{osc}(\mathbf{q}_{true} + \mathbf{b})$ 。条件 (C1) 保证控制律计算时使用的正是 $\mathbf{q}_{true} + \mathbf{b}$, 因此输出的力矩即为 $\boldsymbol{\tau}^{biased}$, 与该小节的定义完全一致。

效应 3 (感知偏差): 第 3.2.3 节 要求观测 $\mathbf{o}$ 中的关节分量为 $\mathbf{q}_{true} + \mathbf{b}$ 、末端位姿分量为 $FK(\mathbf{q}_{true} + \mathbf{b})$, 这恰好是条件 (C2) 的内容。

效应 1 (初始位置偏移): 第 3.2.1 节 的稳态条件 $\mathbf{q}_{true} = \mathbf{q}_{home} - \mathbf{b}$ 是条件 (C1) 应用于底层 PD 控制器的直接推论——当 PD 控制器以 $\mathbf{q}_{target} = \mathbf{q}_{home}$ 跟踪目标、并以 $\mathbf{q}_{true} + \mathbf{b}$ 作为反馈时, 稳态必然停在 $\mathbf{q}_{true} = \mathbf{q}_{home} - \mathbf{b}$ 处。在仿真中如果不显式运行底层 PD 控制器 (见第 3.5.2 节), 直接以 $\mathbf{q}_{true} = \mathbf{q}_{home} - \mathbf{b}$ 初始化关节位置即可达到相同的稳态效果。□

Proposition 3.3 将”故障注入是否忠实”这一问题抽象为两个与架构无关的条件: 不论下层实现是通过 ROS 话题、C++ 内存访问还是仿真的 data 结构, 只要 (C1) 和 (C2) 成立, 注入就等价。这为本节的仿真实现与第六章 的真机 B+D 双注入方案提供了统一的正确性依据。

3.5.2 MuJoCo 中的具体实现

本文的仿真建立于 MuJoCo 3.0 之上, 机器人控制周期为 10 Hz, 内嵌 500 Hz 物理仿真。底层不运行显式的 PD 伺服, 而直接以当前 `data.qpos` 作为真实关节状态; 上层 OSC 控制器通过调用 `mujoco.mj_jacSite` 和 `data.site_xpos` 获得雅可比与末端位置。我们按 Proposition 3.3 的两个条件分别实现三个效应。

效应 1: 初始位置偏移的实现

在 `reset_robot` 阶段, 我们不显式模拟底层 PD 控制器的瞬态, 而是直接将 MuJoCo 的关节位置设为偏移后的稳态值:

$$\mathbf{q}_{data.qpos}^{reset} \leftarrow \mathbf{q}_{home} - \mathbf{b}. \quad (3.22)$$

按式 (3.4)，这正是底层 PD 控制器在反馈被偏差污染时的稳态终点。这一简化跳过了真机上几十至几百毫秒的 PD 瞬态，但在稳态终点上与真机严格一致。由于本文关心的是 episode 内的任务执行（而非初始化过程中的瞬态），这一简化对后续分析没有影响。

效应 2：控制偏差的实现

条件 (C1) 要求 OSC 在计算力矩时使用 $\mathbf{q}_{\text{true}} + \mathbf{b}$ 而不是 $\mathbf{q}_{\text{true}}$ 。由于 `ospace()` 直接从 `data.qpos` 和由此派生的 `mj_forward` 结果中读取关节状态与雅可比，我们采用“临时替换—计算—恢复”的三步式模式：每次物理子步开始时，先将 `data.qpos` 中的手臂关节分量替换为 $\mathbf{q}_{\text{true}} + \mathbf{b}$ 并调用 `mj_forward` 更新内部派生量，随后调用 `ospace()` 计算力矩，再将 `data.qpos` 恢复为真实的 $\mathbf{q}_{\text{true}}$ 并重新 `mj_forward`，最后将计算得到的力矩写入 `data.ctrl` 并由 `mj_step` 驱动物理仿真。完整流程见 Algorithm 1。

算法 1 带编码器偏差的单控制步（ N 次物理子步）

Require: 真实关节位置 $\mathbf{q}_{\text{true}}$ 、期望末端位姿 $\mathbf{x}_{\text{target}}$ 、偏差 $\mathbf{b}$

```

1: for  $k = 1$  to  $N$  do
2:    $\mathbf{q}_{\text{save}} \leftarrow \text{data.qpos}$                                 ▷ 备份真实关节位置
3:    $\text{data.qpos} \leftarrow \mathbf{q}_{\text{save}} + \mathbf{b}$                         ▷ 注入偏差
4:   mj_forward(model, data)                                    ▷ 更新雅可比/FK 等派生量
5:    $\boldsymbol{\tau} \leftarrow \text{ospace}(\text{data}, \mathbf{x}_{\text{target}})$         ▷ 用带偏差的  $\mathbf{q}$  计算力矩
6:    $\text{data.qpos} \leftarrow \mathbf{q}_{\text{save}}$                             ▷ 恢复真实关节位置
7:   mj_forward(model, data)
8:    $\text{data.ctrl}[\text{arm}] \leftarrow \boldsymbol{\tau}$                         ▷ 真实系统施加偏差力矩
9:   mj_step(model, data)                                       ▷ 物理仿真推进
10: end for

```

这一模式的等价性依赖一个简单观察：`ospace` 是 `data.qpos` 经由 `mj_forward` 派生的几何量（ $\mathbf{J}$ 、FK、 $\boldsymbol{\Lambda}$ ）的纯函数，其输出完全由调用时的 `data.qpos` 决定。算法第 3–5 行保证 `ospace` 被调用时关节分量恰为 $\mathbf{q}_{\text{true}} + \mathbf{b}$ ，因此返回的力矩严格等于 $\boldsymbol{\tau}_{\text{osc}}(\mathbf{q}_{\text{true}} + \mathbf{b})$ ——这正是 Proposition 3.3 条件 (C1) 的要求。随后的恢复操作不改变已经算出的力矩值（已被保存到局部变量），只是让物理仿真重新基于真实状态执行。从外部观察，这一流程与“OSC 直接读取被污染的编码器、输出偏差力矩、真实物理按此力矩演化”的真机情形完全对应。

效应 3：感知偏差的实现

条件 (C2) 要求观测模块返回被污染的关节角与末端位姿。在 `get_robot_state()` 中，我们直接构造 $\mathbf{q}_{\text{measured}} = \mathbf{q}_{\text{true}} + \mathbf{b}$ ，并通过一次临时替换计算 $\text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b})$ ：

$$\mathbf{o}_{\text{joint}} = \mathbf{q}_{\text{true}} + \mathbf{b}, \quad \mathbf{o}_{\text{ee}} = \text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b}), \quad (3.23)$$

其中 $\text{FK}(\mathbf{q}_{\text{true}} + \mathbf{b})$ 通过将 `data.qpos` 暂时替换为 $\mathbf{q}_{\text{true}} + \mathbf{b}$ 、调用 `mj_forward`、读取 `data.site_xpos`、再恢复真实值的同一技巧获得，与 Algorithm 1 的替换-恢复模式一致，正确性由同样的“纯函数依赖”论证保证。

3.5.3 外部传感器仿真

除了上述被偏差污染的观测分量外，第 3.4 节的命题 3.2 还要求引入一个独立于编码器的外部位置观测 $\mathbf{o}_{\text{real}}$ 。在仿真中我们将其建模为

$$\mathbf{o}_{\text{real}} = \mathbf{x}_{\text{ee,true}} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_3), \quad \sigma = 5 \text{ mm}, \quad (3.24)$$

其中 $\mathbf{x}_{\text{ee,true}}$ 直接从 MuJoCo 的真实 FK 读取（即 `data.site_xpos` 在真实 `data.qpos` 下的取值，不含偏差）， $\boldsymbol{\epsilon}$ 为独立于时间步与偏差的各向同性高斯噪声。第 3.4 节已经讨论过， $\sigma = 5 \text{ mm}$ 对应 ArUco 视觉标记配合 Intel RealSense D455 在典型工作距离下的外部定位精度。任务目标物体（如方块）的位置则假设由一个俯视外部相机测得，不受编码器偏差影响，在仿真中直接从 MuJoCo 的物体传感器读取。

3.5.4 仿真与真实的主要差距

本节描述的 MuJoCo 仿真是对真实工业机器人系统的理想化近似，主要差距包括：(i) 效应 1 中跳过了底层 PD 控制器的瞬态，而真机上由 `libfranka` 驱动的 1 kHz 伺服存在几十毫秒到数百毫秒的有限响应时间；(ii) 仿真使用 OSC 控制律，而真机 `hil-serl` 架构使用笛卡尔阻抗控制器，两者的等价性将在第 7.3 节严格分析；(iii) MuJoCo 的刚体动力学不包含关节摩擦、电机延迟与线缆影响等真实效应；(iv) 本文只考虑固定与随机偏差，暂未建模温度漂移与电磁噪声等时变偏差类型。

这些差距均朝向使偏差效应在仿真中变弱的方向——摩擦与延迟在真机上会进一步恶化偏差对控制精度的影响，时变偏差在真机上会增加辨识难度。因此仿真可以被视为一个保守的测试平台：若某方法在仿真中能够应对偏差，那么它在真机上更必要、且通常更显著。完整的 8 项对比表与真机注入方案的具体实现将在第六章给出，此处不再展开。

第四章 任务策略：方法设计与共享网络架构

4.1 方法设计动机

第三章从物理因果链与 POMDP 形式化刻画了编码器偏差问题的结构，并通过可观测性分析给出了“信息上能辨识 $\mathbf{b}$ ”的充分条件。本节把这些理论结论转化为三个具体的方法设计选择，并简要说明每个选择的依据与对应章节。

设计选择一：观测空间增强 根据 Proposition 3.1，仅依赖基础本体感觉观测——其中关节角读数 $\mathbf{q} + \mathbf{b}$ 以及由其经正运动学得到的 TCP 位置 $\text{FK}(\mathbf{q} + \mathbf{b})$ 均被偏差污染，而关节速度（编码器读数对时间求导，静态偏差 $\dot{\mathbf{b}} = \mathbf{0}$ 被消去）与夹爪开度（来自控制指令而非编码器）不受偏差影响——无法区分不同的 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 对；而 Proposition 3.2 表明，引入一个独立于编码器的外部位置观测 $\mathbf{o}_{\text{real}}$ 可以打破 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 之间的平移对称性，使系统近似可辨识。因此本文第一个设计选择是**在观测中显式加入外部位置信号**，扩展为 25 维观测空间（含独立的外部 TCP 与人手状态等分量）。具体实现见第 4.2 节。

设计选择二：随机偏差训练 第 3.4.3 节进一步指出，即便信息充分，最优策略仍然是以偏差为条件的函数：对不同的 $\mathbf{b}$ ， π^* 必须输出不同的补偿动作（见式 (3.21)）。若训练过程仅暴露单一固定 $\mathbf{b}$ ，策略只能在该点附近学到“单点条件化”——在偏差分布的其他位置（尤其是 $\mathbf{b} = \mathbf{0}$ ）会产生过补偿现象。因此本文第二个设计选择是**按 episode 从偏差分布 $P(\mathbf{b})$ 中随机采样进行训练**，让策略暴露于整个偏差分布。这一思路与 Tobin 等人在视觉 sim-to-real 中采用的域随机化 [20] 在原则上同源——两者都是“训练时让策略见过未来部署环境的分布”。第 4.3 节将具体描述随机偏差训练，第 5.4.3 节的固定偏差基线实验将给出单点条件化过补偿的直接实证。

设计选择三：仿真验证与真机部署的双端范式 前两个选择回答了“观测什么”和“训练什么分布”，但仍留下“在哪里训练、用什么算法”的执行层问题。本文采取**仿真验证理论与真机模仿部署的双端范式**，由观测模态、数据规模、安全约束三者共同决定。仿真侧采用 Luo 等人的 HIL-SERL 框架 [13]（基于 Ball 等人 RLPD [1] 加人在回路干预），用于验证可观测性命题与随机偏差鲁棒训练（H1-H3 实验），具体训练协议见第 5.2 节。

真机侧因 sparse reward 与 50–200 demo 量级的小数据条件下 SAC online 阶段 actor 解冻会大幅漂移（论文级 negative result，详见??），改用 Kelly 等人 HG-Dagger [11]（人类介入式模仿学习的思路源自 Ross 等人 Dagger [16] 的 query-by-policy 范式；HIL-SERL 与 HG-Dagger 均属 human-initiated 变种）——基于 BC pretrain 的初始策略加操作员介入式纠错，具体训练协议见??。两端在共享方法层面（25 维观测 + 共享网络架构 + 稀疏奖励）一致，仅训练算法与具体协议不同。

真机观测的简化与 future work。真机部署观测进一步简化为 14 维（详见??），其中编码器偏差路径暂未进入观测通道，TCP 信号统一来自外部独立通道——对应 Proposition 3.2 中已被仿真验证的”成功信号路径”。这一简化使真机首跑专注于 sim-to-real 部署 pipeline 与故障注入下的端到端成功率验证（?? 中三任务联合 backup 的 4 列成功率矩阵）；真机层的偏差鲁棒性闭环——把”被污染编码器信号”与”外部位置信号”两路同时投入真机训练——留作第八章的两步 future work 消融。

小结 上述三个设计选择可以简明地映射为表 4.1 所示的”理论-约束-方法”对应关系。后续各节将按此顺序展开具体实现。

表 4.1: 从第三章的理论分析与现实约束到本章方法设计的映射

来源	具体依据	方法设计	展开章节
理论结论	Proposition 3.2（可辨识性）	观测空间增强（25D）	第 4.2 节
理论结论	第 3.4.3 节（条件补偿）	随机偏差训练	第 4.3 节
现实约束	视觉 sim-to-real gap	真机部署与 IL 路径	??
现实约束	稀疏奖励探索困难（仿真侧）	HIL-SERL（demo + HIL bootstrap）	第 5.2 节
现实约束	真机 sparse + 小数据 SAC 漂移	BC pretrain + HG-Dagger	??

4.2 观测空间设计

4.2.1 观测向量构成

任务策略的低维状态观测向量 $\mathbf{o}_t \in \mathbb{R}^{25}$ 由七组分量顺序拼接而成（表 4.2）：前 18 维来自机器人本体感觉通路（编码器读数与控制指令），中间 3 维为独立的外部 TCP 位置，末尾 4 维为人手状态，用于运行时切换到第 5.3 节的备份避让策略。 $\mathbf{o}_{\text{real}}$ 的噪声建模与 TCP 定位方案的抽象化处理见第 4.2.4 节。¹

¹仿真实现层面环境接口为 31 维默认实现，其中方块位置 $\mathbf{o}_{\text{block}}$ 与目标板位置 $\mathbf{o}_{\text{plate}}$ 在本章实验场景下按 episode reset 至确定性位置、对策略恒为常量信道。为避免读者误以为本方法依赖物体真值位置、并与真机简化观测对齐（详见??），本文以剔除两路常量信道后的 25 维形式描述观测空间——常量维度的梯度恒为零，定量结果与原 31 维实现等价（前提是输入归一化对常量信道做特判：本工作通过 compute_dataset_stats.py 中的 const-channel 守卫保证 min-max 归一化在常量信道上不产生 NaN，详见??）。

表 4.2 同时标注了各分量的两个正交性质——是否受偏差 $\mathbf{b}$ 污染与对任务目标的相关性。后者分为四类：**直接相关** ($\mathbf{o}_{\text{real}}$ 与 $\text{FK}(\mathbf{q} + \mathbf{b})$) 直接参与位姿决策；**间接相关** 的关节角 $\mathbf{q} + \mathbf{b}$ 仅在关节极限或几何约束触发时被利用；**结构性的** 关节速度与夹爪开度主要服务于控制闭环的平滑与状态闭合；**运行时安全相关** 的 h_{active} 与 $\mathbf{p}_{\text{hand}}$ 不进入任务奖励梯度——它们的作用是让任务策略与第 5.3 节的备份避让策略共享同一套感知管线，并在运行时被距离判据用作策略切换的依据（任务策略虽然能“看见”人手但不会因此学会避让，避让行为完全由备份策略在切换后承担）。这一分类揭示出本节的核心设计思路：两个直接任务相关的位置量中， $\text{FK}(\mathbf{q} + \mathbf{b})$ 受污染， $\mathbf{o}_{\text{real}}$ 未受污染——正是这组直接相关且彼此不一致的位置信号为策略隐式辨识 $\mathbf{b}$ 提供了信息来源。

表 4.2: 任务策略的 25 维状态观测构成

索引	分量	维度	来源	受偏差污染	任务相关
[0, 6]	关节角 $\mathbf{q} + \mathbf{b}$	7	编码器读数	是	间接
[7, 13]	关节速度 $\dot{\mathbf{q}}$	7	编码器读数对时间差分	否	结构性
14	夹爪开度	1	控制指令	否	结构性
[15, 17]	TCP 位置 $\text{FK}(\mathbf{q} + \mathbf{b})$	3	有偏正运动学	是	直接
[18, 20]	真实 TCP $\mathbf{o}_{\text{real}}$	3	外部定位 + 5 mm 噪声	否	直接
21	人手激活 h_{active}	1	视觉检测管线	否	运行时安全
[22, 24]	人手位置 $\mathbf{p}_{\text{hand}}$	3	视觉检测 + D455 深度	否	运行时安全

4.2.2 信息通路

图 4.1 示意了 25 维观测在两条独立通路上的流动（污染标记见图中红色标签）。需要指出，25 维内部按角色可进一步分为辨识相关与运行时安全两部分：前者包含编码器路径全部 18 维加外部独立 TCP $\mathbf{o}_{\text{real}}$ （共 21 维），是 Proposition 3.2 所要求的可辨识性论证的全部依据——只需一路独立外部位置信号即可打破 $(\mathbf{q}_{\text{true}}, \mathbf{b})$ 的平移对称性；后者包含人手激活 h_{active} 与位置 $\mathbf{p}_{\text{hand}}$ 共 4 维，仅服务于运行时与备份策略的距离触发切换，不参与可辨识性论证。两路联合观测使系统满足近似可辨识性的充分条件——策略原则上可通过比较 $\mathbf{q} + \mathbf{b}$ 与 $\mathbf{o}_{\text{real}}$ 的不一致隐式恢复 $\mathbf{b}$ ，并据此输出第 3.4.3 节所要求的条件补偿动作；其量化误差受 $\mathbf{o}_{\text{real}}$ 噪声 $\epsilon = 5 \text{ mm}$ 与机械臂雅可比条件数 $\kappa(\mathbf{J})$ 限制，具体上界本文不展开。本文不对估计结构施加显式约束（如卡尔曼滤波或专门的 $\mathbf{b}$ 预测头），而交由端到端优化自行组织。

4.2.3 为何保留被污染的本体感觉

一个自然的疑问是：既然 $\mathbf{q} + \mathbf{b}$ 与 $\text{FK}(\mathbf{q} + \mathbf{b})$ 已被偏差污染，为何不直接剔除、仅以 $\mathbf{o}_{\text{real}}$ 作为 TCP 的唯一来源？本文选择保留两者，基于两点考虑。




图 4.1: 25 维观测空间的信息通路示意。编码器路径（左，18D）中的关节角与由其导出的 TCP 位置被偏差 b 污染，关节速度与夹爪开度不受影响；外部观测路径（右，7D）包含独立 TCP 与人手信息，全部与编码器解耦。两路信号在策略网络处汇合，策略原则上可通过 $q + b$ 与 o_{real} 之间的不一致隐式恢复 b 。

信息完整性。按第 3.4.3 节的分析，策略能够辨识 b 的前提是同时持有”被污染的编码器信号”与”独立的外部位置信号”——两者之差才承载偏差信息。若剔除前者，策略仅剩 o_{real} 一路，反而失去推断 b 所需的另一半观测。

运行时容错。真机外部定位系统（ArUco/AprilTag、OptiTrack 等）可能出现短暂遮挡、标记丢失或通讯抖动；保留本体感觉通路意味着当 o_{real} 暂时不可用时，策略仍能退化到”仅依靠本体感觉”的带偏差行为，而非彻底失效。

4.2.4 图像观测与 TCP 定位的通用化处理

图像观测。任务策略另接收前视相机（场景全局视角）与腕部相机（夹爪局部视角）两路 RGB 图像，由冻结的 DINOv3-S（ViT-S/16，约 22 M frozen 参数，自监督预训于 LVD-1689M 数据集）[18] 编码后与 25 维状态观测共享主干（详见第 4.4 节）。仿真渲染与真实相机在纹理、光照与噪声分布上的显著差距正是第 4.1 节论证”真机部署需在真机上继续学习”的直接依据。

real_tcp 的噪声建模。仿真训练中， o_{real} 由 MuJoCo 场景真值叠加 $\mathcal{N}(0, (0.005 \text{ m})^2 \mathbf{I})$ 高斯噪声得到。5 mm 量级与本文真机 ArUco 标定的实测中位误差量级相符（具体标定流程见第六章），以降低 sim-to-real 迁移时因未建模噪声引起的性能衰减。

TCP 定位方案的抽象化。本章不将 o_{real} 绑定到具体实现——可选方案包括 ArUco 或 AprilTag 视觉标记、OptiTrack 光学动捕等，只要该通路满足三条最小要求：独立于关节编码器、能以米制给出 TCP 位置、典型噪声量级与 5 mm 可比。具体选型与标定细节见第六章。

4.3 随机偏差训练

第 3.4.3 节指出，即便观测空间已满足可辨识性条件，最优策略仍必须以偏差 $\mathbf{b}$ 为条件输出不同的补偿动作（式 (3.21)）。若训练过程仅暴露策略于单一固定的 $\mathbf{b}_0$ ，策略至多能在该点附近学到“单点条件化”——一旦部署环境的真实偏差偏离 $\mathbf{b}_0$ （尤其是回到 $\mathbf{b} = \mathbf{0}$ 的标定状态），策略将沿着训练时学到的补偿方向过度修正，产生过补偿现象。本文通过按 episode 随机采样偏差来规避这一问题。

训练协议。 将偏差视为 episode 级环境参数：每次 reset 时为每个关节独立采样 $b_i \sim \mathcal{U}[0, b_{\max}]$ ($i = 1, \dots, 7$)，episode 内保持恒定直至下一次 reset；本文取 $b_{\max} = 0.25 \text{ rad}$ （约 14° ），显著大于第 3.1 节中综述的工业机器人典型偏差量级，用以对策略施加相对激进的压力测试。采样得到的 $\mathbf{b}$ 按第 3.5 节描述的故障注入方式作用于仿真环境内部的编码器读数与控制器参考值，不作为任何形式的额外输入提供给策略——策略只能通过第 4.2 节定义的 25 维观测隐式感知偏差。

与域随机化的联系。 这一做法与 Tobin 等人提出的域随机化 [20] 在原则上同源：两者都依赖“让策略在训练时见过目标部署分布的样本”这一基本思路。但需要指出一个本质区别：Tobin 等人随机化的视觉参数对策略而言是冗余变量（应被忽略），而本文随机化的 $\mathbf{b}$ 是策略必须 *condition* 的隐变量——按第 3.4.3 节的条件补偿要求，最优策略对不同 $\mathbf{b}$ 必须输出不同动作。两者是相反的信息论范式，仅在“训练时见过部署分布”这一表面思路同源；本文的随机化目标是让策略学会从观测中隐式恢复并 *condition* 隐变量，而非习得对它的不变性。另一点区别是，随机偏差训练优化的是偏差分布上的期望回报而非鲁棒 MDP 意义下的最坏情况回报——本文关心的是真机实例之间的平均表现，而非最差情况下的保证性能。

固定偏差基线的实验预告。 为直接验证“单点条件化 $\rightarrow$ 零偏差过补偿”这一假设，第 5.4.3 节设计了固定偏差与随机偏差两组训练的对照实验：两组策略在相同的网络结构与训练超参下，分别暴露于 $b_i = 0.2 \text{ rad}$ （固定，所有 $i = 1, \dots, 7$ ）与 $b_i \sim \mathcal{U}[0, 0.25 \text{ rad}]$ （随机），随后在 $\mathbf{b} = \mathbf{0}$ 以及若干未在训练中出现过的偏差值上分别评估抓取成功率，以刻画两种训练方案在偏差分布上的泛化差异。

网络架构与训练超参的具体形式统一在第 4.4 节给出，适用于本章仿真与真机两条路径。

4.4 网络架构与训练目标

本章描述的任务策略在仿真与真机两端共享同一套网络架构——一个共享编码器、三个独立网络头与对应的训练损失定义。本节依次给出这些具体形式（图 4.2）；具体

训练协议（demo warmup、在线混合采样、HG-DaGger 迭代等）分别见第 5.2 节（仿真 HIL-SERL）与??（真机 BC + HG-DaGger）。




图 4.2: 任务策略的网络架构。三路输入（仿真 25 维 / 真机 14 维状态 + 前视、腕部 128×128 RGB）分别经各自的编码器处理后，按通道拼接为 768 维的共享 feature h ；三个头共享 h 作为输入但输出与训练损失各异——连续 Actor 产生 6 维 Cartesian 末端动作、Twin Critic 输出两个标量 Q 值（取最小以抑制高估）、离散 Gripper Critic 输出 3 维 Q 值选择夹爪动作。DINOv3-S 主干在训练中保持冻结，只更新其后的投影层、状态编码器与三个头。仿真 HIL-SERL 训练四个头的损失，真机 BC 阶段仅训练连续 Actor（critic 与温度参数作为 ckpt schema 占位）。

输入编码。 三路输入的处理管线完整画在图 4.2 中，此处仅陈述要点：仿真 25 维（真机 14 维）状态观测按逐维 Min-Max 归一化到 $[-1, 1]$ 后由 Linear + LN + Tanh 投影到 256 维； 128×128 的前视、腕部 RGB 各自按 ImageNet 均值标准差归一化后送入冻结的 DINOv3-S 主干 [18]（ViT-S/16，约 22 M frozen 参数），输出 patch token 序列被 reshape 成 $384 \times 8 \times 8$ 的 spatial feature map ($128/16 = 8$ patch grid)，再经 SpatialLearnedEmbeddings 与 $F = 8$ 个 learnable spatial kernel 做 channel-wise 加权求和——每个 (c, f) 对（共 384×8 个）输出 $\sum_{h,w} \text{feat}_{c,h,w} \cdot \text{kernel}_{c,h,w,f}$ 一个标量——得 $C \cdot F = 3072$ 维向量，最后过 Dropout(0.1) + Linear($3072 \rightarrow 256$) + LN + Tanh 压到 256 维 latent。该 spatial pooling 设计相对全局平均池化保留了 F 个独立 spatial pattern 的判别力（避免把“物块在左上 vs 右下”混为同一表示），相对 spatial softmax 又能学复杂 attention pattern 而非单一 keypoint。三路 256 维特征按通道拼接得到 768 维共享 feature h 。DINOv3-S 主干参数在 sim 与 real 训练过程中均不更新。

三个网络头。 三个头均以两层 MLP 为主体（隐层维度 [256, 256]、激活函数 ReLU），但输入、输出与训练损失各不相同。连续 Actor 以共享 feature h 为输入，经 [768, 256, 256]

MLP 后并接两个 Linear(256 $\rightarrow$ 6) 头分别输出均值 $\boldsymbol{\mu}$ 与对数标准差 $\log \boldsymbol{\sigma}$ ，通过 `TanhMultivariateNormalDiag` 分布采样得到 6 维连续动作 $\boldsymbol{a}^c \in \mathbb{R}^6$ （对应 3 维末端位置增量与 3 维末端姿态增量）。*Twin Critic* 包含两份独立初始化的 Q 网络 $Q_{\theta_1}, Q_{\theta_2}$ ，各自以 $[\boldsymbol{h}; \boldsymbol{a}^c]$ 为输入、经 [774, 256, 256, 1] MLP 输出标量 $Q \in \mathbb{R}$ ，训练中取两者的最小值以抑制价值高估（Clipped Double Q-Learning）。离散 *Gripper Critic* 以共享 feature 为输入、经 [768, 256, 256, 3] MLP 输出 3 维 Q 值向量，对应代码中编号为 {0:关, 1:保持, 2:开} 的三种离散夹爪动作，采样时取 $\arg \max$ 作为贪婪策略。温度参数 α 以可学习的 $\log \alpha$ 参数化、自动调节（初始值 $\alpha_0 = 0.01$ ），属于独立的优化器参数组。

训练目标。 连续分支遵循 SAC 的标准三个损失（熵正则化与自动温度调节的背景见第二章）：

$$\begin{aligned} L_Q &= \mathbb{E}_{(s, \boldsymbol{a}, r, s') \sim \mathcal{B}} \left[(Q_{\theta}(s, \boldsymbol{a}) - y)^2 \right], \quad y = r + \gamma(1 - d) \left[\min_i Q_{\bar{\theta}_i}(s', \boldsymbol{a}') - \alpha \log \pi_{\phi}(\boldsymbol{a}' | s') \right], \\ L_{\pi} &= \mathbb{E}_{s \sim \mathcal{B}, \boldsymbol{a} \sim \pi_{\phi}} \left[\alpha \log \pi_{\phi}(\boldsymbol{a} | s) - \min_i Q_{\bar{\theta}_i}(s, \boldsymbol{a}) \right], \\ L_{\alpha} &= -\mathbb{E} \left[\alpha (\log \pi_{\phi}(\boldsymbol{a} | s) + \bar{\mathcal{H}}) \right], \end{aligned}$$

其中 $\boldsymbol{a}' \sim \pi_{\phi}(\cdot | s')$ 、 $\bar{\mathcal{H}}$ 为目标熵、 $\bar{\theta}_i$ 为目标网络参数。离散夹爪头则独立地以 Double DQN 形式的 MSE Bellman 损失训练：

$$L_{Q^g} = \mathbb{E}_{(s, a^g, r, s') \sim \mathcal{B}} \left[(Q_{\psi}^g(s, a^g) - y^g)^2 \right], \quad y^g = r + \gamma(1 - d) Q_{\bar{\psi}}^g \left(s', \arg \max_{a'} Q_{\psi}^g(s', a') \right),$$

其中 $a^g \in \{\text{关, 保持, 开}\}$ （即图 4.2 与上一段中代码编号 {0, 1, 2} 对应的三种离散夹爪动作）。仿真 HIL-SERL 训练时四组损失的梯度都反向传播到各自的头参数与共享编码器的可训练部分（DINOv3-S 主干保持冻结），四组参数以各自的 Adam 优化器同步更新。

真机 BC pretrain 阶段仅采用上一段定义的 $L_{\text{BC}} = -\mathbb{E}[\log \pi_{\phi}(\boldsymbol{a} | s)]$ 单一损失，optimizer 只更新连续 Actor 的 MLP 头、状态编码器、SpatialLearnedEmbeddings 与投影层；Twin Critic 与离散 Gripper Critic 在 BC 期间保持随机初始化、不参与梯度更新，仅作为 ckpt schema 占位以便日后切换路径时直接 `--resume` 加载。

训练协议指针。 sim 与 real 的训练协议（demo warmup、在线混合采样、HG-Dagger 介入迭代等具体步骤）分别在第 5.2 节 and ?? 给出。两端共享的训练超参数（学习率、batch size、 γ 、 τ 、 α_0 、image augmentation 等）以双列对照形式列于表 4.3，本节不再赘述协议细节。

表 4.3: 任务策略训练超参数（仿真 HIL-SERL 与真机 BC + HG-DAGger 对照；“—” 表示不适用）

超参数	仿真 HIL-SERL	真机 BC + HG-DAGger
总训练步数	10^5 online	20,000 per BC iter
Demo warmup 步数（纯离线预训练）	500	—
在线阶段首次学习前的环境步数	100	—
UTD 比例（每环境步的梯度更新次数）	2	—
Actor 权重推送频率（Learner $\rightarrow$ Actor）	每 4 个梯度步	—
Batch size $ \mathcal{B} $	256（128 + 128 离线/在线）	256
学习率（actor / critic / α ）	3×10^{-4}	3×10^{-4} （仅 actor）
梯度裁剪范数	40.0	40.0
折扣因子 γ	0.97	—
目标网络软更新 τ	0.005	—
SAC 初始温度 α_0	0.01	—
潜在维度 / MLP 隐层	256 / [256, 256]	同左
缓冲区容量（离线 / 在线）	10^5 / 10^5	—
Image augmentation	—	DrQ random_shift, pad = 4
BC 离散头权重 λ	—	0.5
Tanh-Gaussian σ clamp 范围	—	[10^{-5} , 10]
静止帧过滤阈值 <code>action_norm_min</code>	—	10^{-3} （CLI 覆盖默认 10^{-6} ）
HG-DAGger 介入触发阈值	—	enter 0.05 / exit 0.02
HG-DAGger 释放尾巴 <code>tail_k</code>	—	10 帧
每轮迭代 episode 数	—	30
判停准则（介入率 $\leq 5\%$ 持续）	—	连续 5 episode

4.5 奖励设计

奖励函数。 本文任务策略采用稀疏二值奖励：

$$r_t = \begin{cases} 1 & \text{若 episode 在步 } t \text{ 达成成功判定条件,} \\ 0 & \text{否则.} \end{cases}$$

在仿真训练中，成功判定由 MuJoCo 真值给出：方块与目标板在水平面的投影距离 $\|\mathbf{p}_{\text{block}}^{xy} - \mathbf{p}_{\text{plate}}^{xy}\| < 5 \text{ cm}$ ，且方块 z 坐标 $< 5 \text{ cm}$ （即方块已被放下而非悬在半空）。真机中改采用人工 *keyboard reward* 协议替代自动距离判定：操作员通过四键键盘对每条 episode 给出二值 reward 与 episode 控制信号——**S** 启动 episode、**Enter** 标记成功（ $r = 1$, *terminal*）、**Space** 标记失败（ $r = 0$, *terminal*）、**Backspace** 整条丢弃（设置 `discard=True` 让本 episode 不进入 replay buffer 或 demo pickle）。该协议同时承担 episode 边界控制（无需自动 timeout 检测）与回放过滤（discard 信号），简化了真机数据闭环；具体实现见第六章。每个 episode 在成功 / 失败 / 丢弃 / 步数上限（300 步 @ 10 Hz，即 30s）任一触发时终止；成功时那一步产生 $r_t = 1$ ，其余步为 0。两种机制都给出稀疏二值奖励信号，仅触发源不同（仿真自动判定 vs 真机人工裁决），均不向策略提供距离层面的密集信号。

稀疏奖励的可行性。 一般设定下稀疏奖励常因探索困难而难以收敛，但本文两个具体约束使稀疏奖励反而比密集奖励更合适。

(i) 第 5.2 节的 HIL-SERL 训练框架已通过离线 demo 引导（50 条成功 episode + warmup）与训练全程的人在回路干预解决了稀疏奖励最核心的探索瓶颈——“策略不必”从零摸索出第一次成功”，demo 与干预已经为 critic 提供了充足的正样本与纠错梯度。需指出该论证仅适用于仿真：?? 复盘的真机 SAC 漂移现象表明，即便探索瓶颈被 demo + HIL 解决，critic 仍可能因吞吐量限制无法 calibrate Q 表面、actor 解冻后漂移；探索瓶颈与 Q 估计准确性是两个独立瓶颈，仿真满足前者即可，真机两者都需满足。本文真机改用不依赖 critic 的 BC + HG-Dagger 正是为了绕过 Q 估计瓶颈。

(ii) 除探索瓶颈外，密集奖励本身在本设定下还存在第二重隐患：在编码器偏差下，自然的密集奖励候选（如 $-\|\text{FK}(\mathbf{q} + \mathbf{b}) - \mathbf{p}_{\text{block}}\|$ 形式的 TCP-目标距离）本身就是被污染的信号——它依赖 $\text{FK}(\mathbf{q} + \mathbf{b})$ 而非真实 TCP 位置，因此直接沿该密集信号优化会诱导策略把偏差的几何效应 hack 进 proxy 指标之中、偏离真实目标（即典型的 reward hacking，背景见第二章）。

综合 (i) 与 (ii)，稀疏二值奖励是本文设定下最稳妥的选择。

第五章 仿真：策略训练与可观测性验证

5.1 章节引言：仿真侧范式与本章组织

第四章给出了任务策略的方法设计与共享网络架构（25 维观测、随机偏差训练、DINOv3-S 编码器加三个网络头），但留下了”具体怎么训”这一执行层问题。本章承接第四章的方法层，给出本文**仿真侧**的两条主线及其实验闭环：

- **任务策略仿真训练**（第 5.2 节）：采用 HIL-SERL（RLPD + SAC + 人在回路干预）训练任务策略，配套 Actor-Learner 分布式架构。这一训练用于验证第三章提出的可观测性命题——由第 5.4 节中的 H1（偏差退化基线）、H2/H3（固定/随机偏差对照）、观测维度消融三组实验构成端到端闭环。
- **备份策略仿真训练**（第 5.3 节）：采用纯在线 SAC + 域随机化训练备份避让策略，配套 $V1 \rightarrow V2 \rightarrow V3 \rightarrow V3b$ 的奖励与几何演化。这条主线服务于第六章的真机部署——backup 在真机上不重训，仿真 ckpt 直接迁移。

两条主线在仿真层面相互独立：任务策略关注”如何在编码器偏差下完成抓取”，备份策略关注”如何在人手接近时安全闪避”；运行时由距离判据硬切换协调，详见第六章真机部署。第 5.4 节给出两条主线对应的全部仿真实验数据；第 5.5 节是本章末尾的简短桥接，把仿真已验证的”成功信号路径”过渡到真机部署。

5.2 任务策略仿真训练（HIL-SERL）

第 4.1 节的设计选择三指出，仿真侧采用 HIL-SERL 验证可观测性命题与随机偏差鲁棒训练。本节给出实现这一目标的具体框架：以 Luo 等人提出的 HIL-SERL [13] 为主干，以人在回路干预为持续纠错信号，并通过 Actor-Learner 分布式架构支撑高吞吐异步采样。配套的 H1-H3 实证见第 5.4 节；真机部署因 sparse reward 加小数据下 SAC 收敛性问题改用 BC pretrain 与 HG-DAGger，详见??。

算法栈。 框架的底层是连续动作空间上的 Soft Actor-Critic [5]；其上，Ball 等人提出的 RLPD [1] 通过两个回放缓冲区的 50/50 混合采样为稀疏奖励任务提供 demo 引导——离线演示缓冲区预先装入 50 条人类遥操作的成功 episode，在线缓冲区收集策略与环境

的实时交互，每一步梯度更新都从两侧各采一半，不修改 SAC 损失；本文沿用 RLPD 的高 UTD 比例与 LayerNorm 设计以稳定 critic 训练。HIL-SERL 则在 RLPD 之上进一步将人在回路干预作为训练数据的一等来源贯穿整个在线训练过程（干预数据的具体处理见下段）。

人在回路干预。 在线采样过程中，训练者可通过遥操作设备（键盘、SpaceMouse 等）介入策略正在执行的 episode 并直接给出期望动作；这一“在策略失败的区域由人类示教补充纠错”的思路可追溯到 Ross 等人提出的 DAgger [16]。干预期间产生的转移被统一追加到离线演示缓冲区。本文最初曾尝试仅保留“最终成功”的干预 episode，但在实现与训练过程中发现两点问题：(i) 转移以步为单位写入缓冲区而非按 episode 组织，按成功与否回溯分割需引入额外的边界判定逻辑，且容易因失败率较高而整体丢弃大量有效监督；(ii) 即便 episode 最终未能完成抓取，人类干预所给出的动作方向本身也是可供策略学习的纠错梯度信号。因此最终统一保留所有干预转移，不再依赖最终成功与否进行过滤。

分布式训练架构。 图 5.1 示意训练系统的两个异步进程。Actor 进程持有策略权重副本，负责与仿真环境交互、接收 HIL 干预、把转移写入在线缓冲区；Learner 进程持有两个缓冲区与优化器，负责混合采样、计算 SAC 损失、更新 actor/critic 与温度参数，并定期把最新权重同步给 Actor。两侧通过 gRPC 通讯，使环境采样与梯度更新完全解耦——Learner 以最快速度执行梯度步，Actor 只需按固定的物理控制频率稳定收集转移，梯度计算不会阻塞 env step。该架构同时为日后真机训练保留通路（虽本文真机阶段最终采用 BC 与 HG-DAgger，详见??）。




图 5.1: HIL-SERL 的 Actor-Learner 分布式架构。Actor 负责与环境交互、接收 HIL 干预、写入在线缓冲区；Learner 持有缓冲区与优化器，负责混合采样、SAC 更新并回推权重。两侧通过 gRPC 通讯，环境采样与梯度更新完全解耦。

仿真训练流程。 完整训练由两个在线阶段构成。*Demo warmup* 阶段：训练开始时的前 500 步梯度更新仅从离线缓冲区采样（此时在线缓冲区尚空），用 50 条 demo 为两个 critic 与 actor 建立合理的初始值，避免在线交互起步时因价值函数随机初始化产生不稳定的策略行为。*在线混合采样阶段*：warmup 结束后 Actor 进程开始与仿真环境交互并接收 HIL 干预。其中进入在线阶段后的前 100 个环境步被留作纯数据收集

(`online_step_before_learning` = 100, 只向在线缓冲区写入转移而不触发梯度更新), 其作用在于让在线缓冲区先积累一小批与当前策略分布匹配的样本, 避免在缓冲区几乎为空时就以极度偏置的采样分布破坏 warmup 阶段已获得的初始值。之后进入稳态训练循环: 每个环境步触发 2 次梯度更新 ($UTD = 2$), 每次更新从离线与在线缓冲区各采 $|\mathcal{B}|/2$ 条转移; 干预产生的转移按上一段所述回注离线缓冲区; 每 4 个梯度步 Learner 把 Actor 与离散 critic 的最新权重通过 gRPC 同步推送给 Actor 进程。所有超参数见表 4.3 (仿真 HIL-SERL 列)。

5.3 备份策略仿真训练 (SAC + DR)

本节给出备份避让策略的仿真训练全栈: 问题定义、训练范式选择、场景设计、奖励函数演化、几何升级与域随机化。备份策略与第 5.2 节 任务策略的最大区别是采用纯仿真 SAC + DR 而非 HIL-SERL——下文 第 5.3.2 节 给出范式选择的详细论证。

5.3.1 问题定义与部署场景

工业装配任务通常把机器人工作空间按功能划分为多个区域。本文考虑的 pick-and-place 场景按基座系 Y 轴分为三区 (图 5.2): *Zone A* ($Y < -0.15\text{ m}$) 为物料区, 仅机械臂进入; *Zone C* ($Y > 0.20\text{ m}$) 为人员专用区, 机器人禁入; 中间的 *Zone B* (宽 0.35 m) 为装配区, 亦是**人机共享区**——工人偶尔需从 *Zone C* 一侧伸手进入 *Zone B* 取物料或做手动操作。本节描述的**备份避让策略**即为这类间歇性共享而设计: 人手接近机械臂末端时由其接管、主动避让、结束后交还任务策略。该策略在两种情境下共用同一套机制——(i) 生产部署时的人机协同安全 (主要应用); (ii) 第四章 HIL 训练期间操作者介入时的安全保障 (派生应用)。




图 5.2: 部署场景示意 (俯视)。机械臂把方块从 *Zone A* 搬运到 *Zone B* 的目标板; *Zone B* 同时是人机协同区, 工人偶尔从 *Zone C* 一侧伸手进入。当人手进入 *Zone B* 并距 TCP 小于阈值时, 备份避让策略接管、保证机械臂主动闪避。(示意图, 后期精修。)

安全需求。 备份策略需同时满足四条要求：(1) **避碰**——TCP 与人手距离 $> 8\text{ cm}$ ；(2) **保持夹持**——避让过程绝不放开已夹方块；(3) **Zone C 禁入**——TCP 的 Y 坐标不越 0.20 m ；(4) **原地闪避**——避让期间 TCP 累计位移 $\leq 15\text{ cm}$ ，以保证任务策略能在原位附近恢复执行。违反任一条则 episode 即以 -10 终止，具体奖励形式见第 5.3.4 节。

运行时策略切换机制。 Actor 侧同时持有任务策略与备份策略两套参数，由人手-TCP 欧氏距离决定当前步由哪一套产生动作：距离 $\geq 8\text{ cm}$ 时任务策略动作生效，距离 $< 8\text{ cm}$ 时立即切换到备份策略；备份策略至多连续执行 10 步，期间若人手离开工作空间或步数用尽则切回任务策略。这一“距离触发 + 时间有界”的硬切换把备份策略的训练目标简化为“在 10 步内避让并稳定”，与任务层面的语义完全解耦。真机部署的具体阈值与几何对齐 (Route A center-dist) 见??。

5.3.2 训练范式选择

设计演化：从硬编码冻结到分离式学习。 当前的分离式双策略设计经历过两次失败迭代，env 本身始终是统一的——任务策略与备份策略共享同一个 `PandaPickPlaceSafeEnv` (见第 4.2 节 25 维观测定义里的 h_{active} 与 p_{hand} 分量)，发生变化的是如何“学习避让”以及如何在运行时协调两个目标。最早的方案是硬编码冻结——当人手距 TCP 小于阈值时任务策略停止输出、机械臂保持当前构型。这一方案在静态安全性上成立，可以满足 HIL 训练期间的最低安全要求；但它**非学习型**（硬编码规则无法根据障碍物运动模式做差异化响应、没有研究新颖度）且**被动低效**（每次人手接近都完全中断任务，若人手沿原方向继续逼近，静止的末端仍可能被动接触）。为提升避让行为的主动性并使其成为学习型方法，第二次尝试是统一学习策略——用同一个策略同时优化任务完成与避让，奖励沿用与第 4.5 节 相同的稀疏二值形式（成功 = 1、任何失败 = 0）。训练出现典型的 reward hacking：策略学会在人手出现时加速冲向目标板、抢在碰撞前完成放置，而不是先避让再完成。原因在于该奖励不区分两类失败——碰撞与超时的惩罚都是 0，策略对避让没有梯度信号；而“冲刺完成”的路径在人手到达前完成任务的概率非零，期望回报上优于“避让后完成”。这两次失败共同导出本节的最终架构：**env 不变（仍然共享 25 维统一观测）**，把学习目标拆成两个专门的策略——任务策略保留原稀疏 0/1 奖励（第 4.5 节），仅优化“抓方块、放目标板”，对观测里的 h_{active} 、 p_{hand} 不产生避让响应；避让另开一个备份策略、采用专门设计的非负即时 + 大终止惩罚奖励（第 5.3.4 节）。两者由运行时距离判据硬切换——既保留了硬编码冻结的安全下界，又通过学习型主动避让规避了“中断任务”与“被动接触”两种低效情形。

架构灵感：Kiemel 等人 2024。 本节的整体架构受 Kiemel 等人 [12] 启发：他们先用无模型 RL 训练一个 backup policy 产生避让动作，然后在学习其他任务时把它作为安全层——每步决策前估计碰撞风险，若风险过高则用 backup 的动作替换。本文沿用“预先训练 backup、运行时切换”的思路，并做两处调整：(i) 把使用场景从通用任务学

习的安全层换成 HIL 训练与装配区人机协同;(ii) 把在线风险估计简化为基于人手-TCP 距离的硬切换,降低真机部署的计算与工程复杂度。奖励设计层面本文保留了其核心原则——非负即时奖励 + 大终止惩罚。

为何采用纯仿真 + 域随机化。 与第 5.2 节 任务策略的 HIL-SERL 形成对照,备份策略采用纯仿真 SAC + 域随机化而非 HIL 训练。四点理由: (i) 观测模态——输入为低维状态、无 RGB 图像,不存在视觉 sim-to-real gap; 低维观测的差距(位置噪声、速度抖动、检测延迟)由 DR 精确覆盖(第 5.3.6 节)。(ii) 递归安全——若备份本身也需 HIL 训练,则训练它时又需要一个更底层的”备份的备份”来保障操作者安全,无穷退化; 纯仿真从根本上绕开这个问题。(iii) 可评估性——仿真可以构造覆盖完整的障碍物运动场景,并以碰撞真值直接评估策略安全性。(iv) 偏差鲁棒性——避让行为主要依赖障碍物与 TCP 的相对几何而非绝对位置,DR 观测噪声使策略对大致方向而非精确位置作反应,因此 backup 对编码器偏差天然鲁棒、无需 bias-aware 训练; 实证上,把无偏差环境下训练的备份 checkpoint 直接在带 joint 1 随机偏差的评估环境下运行,存活率与无偏差环境基本一致(详见第 5.4 节)。

5.3.3 场景、观测与运动模式

本节给出备份策略的仿真环境设计——两个训练场景、单帧观测向量的构成、帧堆叠策略,以及四种障碍物运动模式。

场景 S1 / S2 与观测向量。 本节在两个递进的仿真场景上训练备份策略: S1 含一个间歇性出现的移动障碍物(模拟单只人手); S2 在 S1 基础上额外放置一个位置随机但固定不动的静止障碍物(模拟工作台上的固定物件)。两个场景共享相同的单帧观测结构——18 维机器人状态(7 关节角 + 7 关节速度 + 1 夹爪开度 + 3 TCP 位置)加每个障碍物的 10 维观测(1 维激活标志 + 3 维绝对位置 + 3 维差分速度 + 3 维相对 TCP 位置)。S1 单帧 28 维, S2 单帧 38 维。激活标志刻画障碍物的间歇出现: 障碍物在工作空间内为 1、离开后变为 0,从而策略可以在障碍物消失时回到正常状态、在下次出现时重新进入避让。

帧堆叠。 单帧观测已含障碍物的差分速度,但不同运动模式在时序上呈现出显著不同的特征——STOP_GO 的周期性停顿意味着”当前速度 ≈ 0 ”可能是真正停止也可能是短暂停顿; PASSING 的加速横穿与 LINEAR 的匀速直线只有在观察连续数步后才能可靠区分。为让策略基于一小段历史而非单一瞬时观测判断,本节对单帧观测做 3 帧堆叠:

$$\mathbf{o}_t^{\text{stack}} = [\mathbf{o}_{t-2}^{\text{single}}; \mathbf{o}_{t-1}^{\text{single}}; \mathbf{o}_t^{\text{single}}],$$

从而 S1 的完整观测为 $28 \times 3 = 84$ 维, S2 为 $38 \times 3 = 114$ 维。这等价于在观测层面隐式提供了二阶运动信息(加速度与模式特征),使策略能识别运动模式并对短时未来运动作出预测。

障碍物运动模式与 episode 设定。 每个 episode 开始时从四种运动模式中均匀随机选择一种并在 episode 内保持不变（表 5.1），以覆盖人手接近的典型模式；策略须对全部四种模式保持鲁棒。训练 episode 长度固定为 10 步（@ 10 Hz，即 1 s），并采用无折扣设定 $\gamma = 1.0$ ——在这样短的 episode 下每一步的安全性等价重要，任何折扣都会人为扭曲避让行为在时间维度上的权重。

表 5.1: 备份策略训练中的四种障碍物运动模式

模式	轨迹	关键参数	模拟场景
LINEAR	匀速直线朝 TCP	—	人直接伸手取物
ARC	弧线绕向 TCP	每步方向向量旋转 $\omega \sim \mathcal{U}(-0.1, 0.1)$ rad	人从侧面绕过
STOP_GO	朝 TCP 随机停顿	每步 30% 概率停顿	人犹豫后再伸手
PASSING	垂直于 TCP 方向横穿	速度 $\times 1.3$	人手路过而非针对机器人

5.3.4 奖励函数设计演化

备份策略的奖励函数经历三次迭代——V1 / V2 / V3，每次失败暴露出一种典型的 reward hacking 模式，共同导出 V3 的最终形式；V3 在真机部署阶段进一步演化为 V3b 几何（详见第 5.3.5 节）。本小节按时间顺序陈述三个版本并总结设计原则；具体训练曲线与量化对比属于实验部分，留至第 5.4 节。

V1：接近度奖励及其失败。 V1 采用“远离障碍物”式的即时奖励——以 TCP 与最近障碍物的距离为驱动信号：

$$r_t^{V1} = r_{\text{prox}}(d_t^{\text{obs}}) - 0.01\|\mathbf{a}_t\|, \quad r_{\text{prox}}(d) = \min(1, (d/d_{\text{danger}})^2),$$

其中 d_t^{obs} 为 TCP 与最近障碍物之间的欧氏距离；碰撞时 $r_{\text{term}} = -1.0$ 。问题在于 r_{prox} 直接奖励远离——策略学到的最优行为是尽可能跑得远，而不是留在原位小幅闪避。这与本节部署需求（第 5.3.1 节 安全要求 (4)“原地闪避”）直接冲突：策略“避让了人手”却“丢失了任务位置”。教训：奖励必须与部署目标对齐——避让的目标不是“离障碍物越远越好”，而是“既不碰撞也不远离”。

V2：全负奖励及其失败。 V2 改为全负软约束形式，以位移 + 动作幅度 + 动作平滑三项惩罚劝阻策略跑远。为书写紧凑引入两个缩写： $\Delta \mathbf{p}_t := \mathbf{p}_t^{\text{TCP}} - \mathbf{p}_0^{\text{TCP}}$ （相对 episode 起点的累计位移）， $\Delta \mathbf{a}_t := \mathbf{a}_t - \mathbf{a}_{t-1}$ （动作增量），则每步奖励为

$$r_t^{V2} = -0.5\|\Delta \mathbf{p}_t\| - 0.01\|\mathbf{a}_t\| - 0.01\|\Delta \mathbf{a}_t\|,$$

碰撞终止 $r_{\text{term}} = -1.0$ ， $\gamma = 0.99$ 。问题在于存活每一步都带来负奖励——完整存活 10 步的总回报约为 -0.5 到 -0.8 之间，一旦第 1 步碰撞则为 -1.0 ，两者差距仅 ~ 0.2 ；

位移积累稍大时存活总回报甚至比立即碰撞更糟。策略学到的最优行为变成了尽快终止(“快死优于慢死”), 训练日志中平均奖励由 -0.88 持续恶化到 -1.00 、episode 长度逐步缩短直至几乎每回合首步即碰撞(完整曲线见第 5.4 节)。教训: 存活必须严格优于任何终止——即时奖励不能为负, 且终止惩罚必须远大于任何可能的存活轨迹累积回报。

V3: 非负即时奖励 + 大终止惩罚。 V3 严格遵循 Kiemel 等人 [12] 的“每步即时奖励非负、终止给予大惩罚”原则, 并在软奖励中保留位移项以实现“原地闪避”目标。存活每一步的即时奖励为

$$r_t^{V3} = 0.5 - 0.5\|\Delta \mathbf{p}_t\| - 0.01\|\mathbf{a}_t\| - 0.01\|\Delta \mathbf{a}_t\| \geq 0,$$

在碰撞、方块掉落、TCP 越 Zone C、或累计位移 $\|\Delta \mathbf{p}_t\| > 15 \text{ cm}$ 任一触发时, episode 以大终止惩罚 $r_{\text{term}} = -10.0$ 结束; 若 episode 安全存活满 10 步则额外给予 $+5.0$ 完成奖励; 折扣 $\gamma = 1.0$ 。表 5.2 列出几种典型场景的总回报: 不动 $+10.0 >$ 小闪避 $\approx +9.7 >$ 大闪避 $\approx +8.5 \gg$ 碰撞或过度反应 -10.0 。这一排序有三个关键性质: (i) 每步即时奖励非负, 存活永远优于提前终止, 消除了 V2 的“快死”漏洞; (ii) 终止惩罚远大于任何存活轨迹的累积上限 ($|-10.0| \gg +10.0$), 主动终止不是期望回报上的优解; (iii) 不动 $>$ 小闪避 $>$ 大闪避的软排序让策略在可以不动时倾向于不动(对齐“原地闪避”目标, 消除了 V1 的“跑远”漏洞), 不得不动时倾向于小幅动作。

表 5.2: V3 奖励下典型场景的总期望回报 ($\gamma = 1.0$, 10 步 episode)

场景	行为描述	总回报
完美静止	原地不动、人手路过未接触	$+10.0$
小幅闪避	累计位移 $\approx 5 \text{ cm}$ 后存活	$\approx +9.7$
大幅闪避	累计位移 $\approx 12 \text{ cm}$ 后存活	$\approx +8.5$
过度反应	累计位移 $> 15 \text{ cm}$ 触发硬约束	-10.0
碰撞失败	首步未闪避、与人手相撞	-10.0

设计原则总结。 V1 $\rightarrow$ V2 $\rightarrow$ V3 的三次迭代归纳出四条在避让类短 episode 任务上普遍适用的奖励设计原则: (1) 即时奖励必须非负, 保证存活严格优于任何终止; (2) 终止惩罚必须远大于任何存活轨迹的累积上限, 防止“主动终止”成为最优解; (3) 位移等跨 episode 的硬约束必须用终止惩罚而非软惩罚表达, 避免通过累积软惩罚规避终止; (4) 短 episode 任务应使用无折扣设定 $\gamma = 1.0$, 避免把安全权重在时间维度上做不必要权衡。

5.3.5 V3 $\rightarrow$ V3b 几何升级: 从单球到 5 球全臂

V3 奖励的几何模型只检测 panda_hand 单球与障碍物的距离。真机部署阶段(??)发现该模型存在一个失效模式: 策略学会让 panda_hand 避开障碍物, 但肘部与前臂仍

可能撞向障碍物——单球检测无法捕获 link3/link4 等中段链节的碰撞风险。本文据此把 V3 升级为 V3b 几何，包含三处改动：

1. 多球全臂检测：单球（仅 panda_hand，半径 0.10 m）扩展为 5 球（link3, link4, link5, link6, hand，半径分别为 0.07, 0.07, 0.065, 0.065, 0.10 m）。碰撞判定取所有球的最小距离，使训练奖励直接覆盖肘/前臂触障风险。
2. 障碍物半径与 TCP-障碍物距离调整：障碍物半径从 0.035 m 提升至 0.10 m（对齐真机 hand bbox 等效半径）；障碍物 spawn 距离从 $\mathcal{U}(0.21, 0.30)$ m 提升至 $\mathcal{U}(0.30, 0.40)$ m；手速从 $\mathcal{U}(0.005, 0.015)$ m/step 提升至 $\mathcal{U}(0.015, 0.030)$ m/step；最大允许位移从 0.30 m 提升至 0.40 m。
3. *Saturating proximity bonus*：在 V3 reward 上加入饱和接近奖励（饱和值 0.20 @ clearance 0.10 m），让策略对临界距离（接近但不碰撞）有正梯度信号，避免 V3 在多球检测下因“远离即可”训不出精细避让。

V3b 配套的 FSM 阈值升级见?? (Route A center-dist: $D_{\text{SAFE}} 0.30 \rightarrow 0.40$ m, $D_{\text{CLEAR}} 0.35 \rightarrow 0.45$ m)。V3b 训完版 (backup_policy_s1_v3b_300k) 在真机首选 ckpt 中存活率 95.0%，相对 V3 单球版 71.5% 显著提升；hand_collision 率从 17.5% 降至 3.0%（详见第 5.4 节）。

5.3.6 训练协议与域随机化

网络架构（相对第 4.4 节的简化）。 备份策略的网络主体与第 4.4 节 完全同构——SAC 的连续 Actor 与 Twin Critic 都以隐层 [256, 256]、激活 ReLU 的 MLP 为主体，学习率、梯度裁剪、目标网络软更新等基础超参均复用任务策略的设定。动作空间为 6 维连续末端增量 ($\Delta x, \Delta y, \Delta z, \Delta r_x, \Delta r_y, \Delta r_z$)、单步缩放 0.03 m，夹爪在备份策略激活期间始终锁定、不参与动作。两处简化：(i) 输入为低维状态、无视觉编码器；(ii) 采用纯在线 SAC，无离线 demo 缓冲区、不做 RLPD 式的 demo bootstrap。其余非零差异列于表 5.3。其中 UTD 比例取 8（相对任务策略的 2 显著提高），是对“短 episode、在线数据稀少”的一种补偿；训练过程中也试过 $\text{UTD} \in \{2, 4\}$ 等设定，对最终存活率基本无影响，仅影响训练收敛的 wall-clock 速度。

域随机化参数。 域随机化仅作用于观测层，碰撞检测始终使用真实位置——这是安全边界的底线：DR 让策略对感知噪声鲁棒，但不应让策略在“假碰撞”上练习避让。具体参数见表 5.4，各项的真机来源将在下段 sim-to-real 对齐分析中一一对应。

Sim-to-Real 对齐分析。 表 5.5 按观测与控制链上的每一个环节比较仿真与真机间的差距。核心观察是：**机器人自身状态** ($\mathbf{q}, \dot{\mathbf{q}}$, TCP) 由编码器直接读出，在 sim 与 real 之间没有 gap（这也正是本节选择纯状态观测的主要动机）；而所有与**障碍物感知**相关的维

表 5.3: 备份策略相对任务策略的关键超参数差异

超参数	任务策略（第四章）	备份策略（本节）
离线 demo 缓冲区	50 episodes	无
总在线训练步数	10^5	2×10^5 (V3b 训 3×10^5)
UTD 比例	2	8 (V3b 调回 4 防过拟合)
SAC 初始温度 α_0	0.01	0.1
在线缓冲区容量	10^5	2×10^5
Episode 长度	200 步	10 步 (V3b 20 步)
折扣因子 γ	0.97	1.0

表 5.4: 备份策略训练中的域随机化参数

参数	分布	模拟内容
障碍物位置噪声	$\mathcal{N}(\mathbf{0}, 0.03^2 \mathbf{I}_3) \text{ m}$	视觉 + 深度的累计定位误差
障碍物速度噪声	$\mathcal{N}(\mathbf{0}, 0.01^2 \mathbf{I}_3) \text{ m/step}$	帧间差分抖动
观测延迟	$\mathcal{U}\{0, 1, 2\}$ 步	视觉检测 + 推理延迟
障碍物生成距离	$\mathcal{U}(0.30, 0.40) \text{ m}$ (V3b)	不同的进入距离
障碍物移动速度	$\mathcal{U}(0.015, 0.030) \text{ m/step}$ (V3b)	不同的手速
TCP 位置噪声	$\mathcal{N}(\mathbf{0}, 0.005^2 \mathbf{I}_3) \text{ m}$	外部 TCP 定位的单帧误差

度（位置、速度、延迟）都依赖外部视觉系统，必须由 DR 覆盖。控制器从仿真的 OSC 到真机的笛卡尔阻抗控制存在结构差异，但在小步 TCP 增量动作空间上近似等价，严格论证见第六章。

表 5.5: 备份策略的 Sim-to-Real 差距分析

环节	仿真来源	真机来源	Gap 弥补方式
机器人状态 $\mathbf{q}, \dot{\mathbf{q}}, \text{TCP}$	MuJoCo 真值	关节编码器	无 gap
手部位置	MuJoCo 真值	视觉检测 + D455 深度	DR 位置噪声（详见??）
手部速度	真值差分	视觉结果帧间差分	DR 速度噪声
观测延迟	0	$\sim 10 \text{ ms}$ 检测延迟	DR 延迟 $\mathcal{U}\{0, 1, 2\}$ 步
坐标变换	无	$T_{\text{cam} \rightarrow \text{robot}}$ 标定	含入位置噪声项
控制器	OSC	笛卡尔阻抗控制	小步增量下近似等价（第六章）
障碍物运动模式	4 种预设模式随机	真实人手动作	4 种模式覆盖典型动作

手部检测器的具体选型（MediaPipe 初选 $\rightarrow$ WiLoR 部署演化）属于真机部署决策，搬到?? 详述。

5.4 仿真实验与分析

本节给出本章两条主线（任务策略 HIL-SERL + 备份策略 SAC + DR）对应的全部仿真实验数据。所有实验均在 PandaPickCube / PandaPickPlaceSafe / PandaBackupPolicy

系列 MuJoCo 环境中完成，每个偏差值评估 50 episodes，每组超参数训练 3 个 seed。

5.4.1 实验设置

环境。 基于 MuJoCo 3.0 的 7-DoF Franka Panda 仿真，OSC 控制 10 Hz、物理仿真 500 Hz。任务策略评估在 PandaPickCube 上完成：抓取桌面方块、抬升 20 cm 即视为成功。备份策略评估在 PandaBackupPolicyS1 / S2 上完成：每 episode 等概率从表 5.1 四种模式随机选一种障碍物运动，存活满 10 步且未触发任何终止条件视为成功。

统计协议。 每组实验 3 seeds，每 seed 评估 50 episodes，报告 $\text{mean} \pm \text{std}$ ；偏差扫描时每个偏差值独立 50 episodes。训练超参除特别说明外按表 4.3 与表 5.3 默认设定。

5.4.2 H1：编码器偏差退化基线

假设。 无偏差训练得到的策略在编码器偏差下性能退化。

实验。 训练无偏差策略(PickCube 18D 观测, 无 `real_tcp`), 在 $b \in \{0.0, 0.05, \dots, 0.30\}$ rad 下分别评估。

结果 (表 5.6): 偏差 > 0.10 rad 起成功率显著下降, ≥ 0.25 rad 接近完全失败; 末端位置随偏差线性偏移 (每 0.05 rad 约 3 cm)。这一退化曲线直接对应 Proposition 3.1: 基础观测下偏差不可辨识, 策略无法对不同 b 做差异化补偿。

表 5.6: H1: 无偏差策略在不同 J5 偏差下的退化

Bias (rad)	成功率	平均步数	TCP 偏移
0.00	100%	13.5	0 cm
0.05	100%	13.5	~ 3 cm
0.10	80%	55.9	~ 6.5 cm
0.15	62%	62.5	~ 10 cm
0.20	51%	99.8	~ 13 cm
0.25	5%	184.5	~ 16 cm
0.30	0%	191.1	~ 19 cm

5.4.3 H2 + H3：固定 vs 随机偏差训练

假设。 固定偏差训练导致单点条件化与零偏差过补偿; 随机偏差训练实现全范围鲁棒。

实验。 三组对照训练 (PickCube 24D 观测, 含 `real_tcp`): (a) 无偏差; (b) 固定 $b = 0.2$ rad; (c) 随机 $b \sim \mathcal{U}[0, 0.25]$ rad。各自训完后在全偏差扫描上评估。

结果 (表 5.7):

- 无偏差策略: $b = 0$ 完美但 $b > 0.10$ 起退化 (同 H1)。

- 固定偏差策略：训练点 $b = 0.2$ 附近 99%+，但 $b = 0$ 时降至 83%——**零偏差过补偿**的直接实证，对应第 3.4.3 节的”单点条件化 $\rightarrow$ 过补偿”论断。
- 随机偏差策略：全范围 92–100% 鲁棒，且**超训练范围泛化** ($b = 0.30$ rad 仍 99%，训练上限 0.25)。

表 5.7: H2 + H3: 三种策略在偏差扫描下的成功率对比

Bias (rad)	无偏差策略	固定 $b = 0.2$ 策略	随机 $b \in [0, 0.25]$ 策略
0.00	100%	83%	92%
0.05	100%	87%	100%
0.10	80%	99%	99%
0.15	62%	100%	96%
0.20	51%	100%	97%
0.25	5%	100%	96%
0.30	0%	99%	99%

5.4.4 观测空间消融：从 18D 到 24D

假设。观测维度的可辨识性结论可被消融实验直接验证——剔除独立外部 TCP $\mathbf{o}_{\text{real}}$ 后偏差不可辨识、训练失败。

实验。三档观测空间对照 (PickCube, 随机偏差训练)：18D (无 `real_tcp` 与 `block_pos`) / 21D (仅加 `block_pos`) / 24D (再加 `real_tcp`)。

结果 (表 5.8)：

- *18D*: 仅 robot proprio, 全偏差扫描平均 42%——基础观测下偏差不可辨识，对应 Proposition 3.1。
- *21D*: 加目标位置但仍无独立 TCP，训练不收敛——”知目标不知己”，无法补偿编码器偏差。
- *24D*: 再加 `real_tcp` 后达到 92–100%——Proposition 3.2 的可辨识性条件被满足，策略隐式恢复 $\mathbf{b}$ 并条件补偿。

表 5.8: 观测空间消融：理论预测与实测的一一对照

观测	维度	缺少的关键信号	结果	理论预测
18D	18	<code>real_tcp</code> + <code>block_pos</code>	42% avg	不可辨识 (Proposition 3.1)
21D	21	<code>real_tcp</code>	训练失败	知目标不知己
24D	24	(完整)	92–100%	近似可辨识 (Proposition 3.2)

说明。 本组消融在 PickCube 24D 上做以隔离编码器偏差因素; 第 4.2 节 描述的部署 25D 观测是 24D + hand 通道的等价扩展 (hand 通道不参与可辨识性论证, 仅服务运行时 backup 切换), 消融结论可类比扩展到 25D 部署观测。

5.4.5 Backup S1 V3b 主存活率

实验。 在 PandaBackupPolicyS1 V3b 几何 (第 5.3.5 节) 上训练 3×10^5 步, $\max_disp = 0.50$ m; 在 200 episodes (每模式 50 episodes) 上评估。

结果。 V3b 训完版 (backup_policy_s1_v3b_300k):

- 满存活率: 95.0% (vs V3 单球版 71.5%, vs V2 单球版 100% 但真机存在肘撞)
- 失败模式分布: hand_collision 3.0%(V3 单球版 17.5%, 下降 $5\times$); excessive_displacement 5.5%
- 运动模式分项: LINEAR / ARC / STOP_GO / PASSING 全部 $\geq 90\%$, 最弱 ARC 90.5%

V3b 几何升级是真机部署观察到的失效模式倒逼仿真升级的案例 (第 5.3.5 节 已展开); V3 单球版作为对照保留, 证明几何升级是必要的。

5.4.6 Backup 偏差鲁棒性 zero-shot

假设。 备份策略对编码器偏差天然鲁棒、无需 bias-aware 训练 (第 5.3.2 节 第四点理由的实证)。

实验。 用 第 5.4.5 节 的 S1 baseline checkpoint (无偏差训练), 分别在两个评估环境跑 200 episodes: (a) PandaBackupPolicyS1 (无偏差); (b) PandaBackupPolicyS1BiasJ1 (J1 随机偏差 $b_1 \sim \mathcal{U}[0, 0.25]$ rad)。

结果。 存活率 baseline 99.0% vs BiasJ1 98.5%, 差距 0.5% 在 200 ep 抽样噪声范围内 ($\pm 1.5\%$ at 95% CI)。备份策略使用真实 TCP sensor 而非 biased FK, 所以偏差对 backup 几乎不可见——印证”DR 训练策略对观测扰动鲁棒”且”backup 无需 bias-aware 训练”。

5.4.7 Reward V1 / V2 / V3 演化训练曲线

实验。 三组训练在同一 PandaBackupPolicyS1 环境、同一 SAC 超参下使用三种奖励: V1 (接近度) / V2 (全负) / V3 (非负 + 大终止)。每组 3 seeds、 2×10^5 步。

记录指标。 V1: 平均 TCP 累计位移 (应逼近 15 cm 上限); V2: 平均 episode 奖励 (应从 ~ -0.88 持续恶化到 ~ -1.00) + 平均 episode 长度 (应缩短); V3: 平均 episode 奖励 (应稳定收敛到 $\sim +9$ 到 $+10$) + 存活率 (应升至 $\sim 99\%$)。

结果。 三组训练曲线印证 第 5.3.4 节 的设计原则:

- V1: 策略学会跑远, 平均位移逼近 15 cm 上限, 触发 `excessive_displacement` 大量终止——典型的 reward hacking。
- V2: 平均奖励 $-0.88 \rightarrow -1.00$ 单调恶化, episode 长度缩短到几乎首步即碰撞——“快死优于慢死”。
- V3: 稳定收敛到 +9 到 +10 区间, 存活率升至 $\sim 99\%$, 对应第 5.4.5 节的最终结果。

5.4.8 Backup S2 多障碍场景扩展

实验。PandaBackupPolicyS2 (移动 + 静止双障碍), 114D 观测 (38×3 帧堆叠), $UTD = 4$ ($UTD = 8$ 训 1×10^5 步崩溃), 2×10^5 步。

结果。存活率 83–91% (两次 eval 方差较大); `hand_collision` 率 13.5% (vs S1 baseline 0.5%, 升 $26\times$); 最弱模式 ARC 75.0% / STOP_GO 81.8%、最强模式 PASSING 91%。从单障碍 99% 到多障碍 $\sim 85\%$ 是**多障碍几何本身更难** (逃生锥变窄、样本组合从 50 升到 2500), 不是策略学不好。证明本节架构在多障碍场景上仍可扩展。

5.5 仿真到真机的桥接

本章的 sim 实验闭环 (H1+H2+H3 任务策略 / Backup S1 V3b / Reward V1 $\rightarrow$ V3 / S2 多障碍) 共同支撑下一章的真机部署:

- Proposition 3.2 已被 第 5.4.4 节 24D 消融实证为信息论上“成功的信号路径”——真机 14D 观测 (详见??) 正是采用这条已验证路径 (外部独立 TCP), 暂不引入被污染的编码器路径, 使真机首跑专注于部署 pipeline 与端到端成功率验证。
- Backup 策略 `backup_policy_s1_v3b_300k` 直接用作真机 ckpt (不重训), 配套?? 的 Route A center-dist 几何对齐与 $D_{SAFE} = 0.40$ m 阈值。
- Reward V3 $\rightarrow$ V3b 几何升级是真机部署观察到的失效模式 (V3 单球版肘/前臂撞) 倒逼仿真升级——第 六 章 在描述备份策略真机表现时会回过来引用本章 V3b 数据。
- HIL-SERL 在仿真中稳定收敛但真机失败的对照分析见?? (真机 negative result 复盘)。

下章第 六 章 给出真机部署的完整栈: 硬件架构与 B+D 偏差注入、任务策略真机部署 (BC + HG-DAGger)、备份策略真机部署 (WiLoR + Route A FSM)、以及三任务联合 fault injection 4 列成功率矩阵——本论文的核心实验数据。

第六章 真机：模仿部署与端到端验证

6.1 占位（C3 重组中）

本章正在重组中，将合并以下内容：

- 真机系统架构与编码器偏差注入（搬自旧 第四章 真机部分与原 Ch.7）
- 任务策略真机部署：BC pretrain + HG-Dagger (`sec:real_task_deploy` 待建)
- 备份策略真机部署：手部检测演化、Hierarchical Supervisor、Route A 几何对齐 (`sec:backup_real_deploy` 与 `sec:hand_detection_evolution` 待建)
- 真机实验与分析：三任务 4 列联合成功率矩阵 论文核心数据(`sec:real_experiments` 待建)
- HIL-SERL 真机失败的方法论复盘 (`subsec:hilserl_failure` 待建)

详见下一 commit C3。

第七章 真机部署与验证

7.1 硬件架构

7.2 真机故障注入方案

7.3 OSC 与阻抗控制的等价性

7.4 外部定位方案

7.5 实验结果

第八章 总结与展望

8.1 工作总结

8.2 局限性

8.3 未来工作

参考文献

- [1] Philip J. Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. “Efficient Online Reinforcement Learning with Offline Data”. In: *Proceedings of the 40th International Conference on Machine Learning (ICML)*. Vol. 202. Proceedings of Machine Learning Research. PMLR, 2023, pp. 1577–1594.
- [2] Mogens Blanke, Michel Kinnaert, Jan Lunze, and Marcel Staroswiecki. *Diagnosis and Fault-Tolerant Control*. 3rd ed. Berlin, Heidelberg: Springer, 2016. ISBN: 978-3-662-47942-1. DOI: 10.1007/978-3-662-47943-8.
- [3] Franka Robotics. *Franka Control Interface (FCI) Documentation*. <https://frankarobotics.github.io/docs/overview.html>. Version 0.6.0, accessed 2026-04-12. 2024.
- [4] Chunhe Gong, Jingxia Yuan, and Jun Ni. “Nongeometric error identification and compensation for robotic system by inverse calibration”. In: *International Journal of Machine Tools and Manufacture* 40.14 (2000). Models geometric, compliance, and time-variant thermal errors in industrial robots via laser-tracker inverse calibration., pp. 2119–2137. DOI: 10.1016/S0890-6955(00)00023-7.
- [5] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. “Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor”. In: *Proceedings of the 35th International Conference on Machine Learning (ICML)*. Vol. 80. Proceedings of Machine Learning Research. PMLR, 2018, pp. 1861–1870.
- [6] Sami Haddadin, Alessandro De Luca, and Alin Albu-Schäffer. “Robot Collisions: A Survey on Detection, Isolation, and Identification”. In: *IEEE Transactions on Robotics* 33.6 (2017), pp. 1292–1312. DOI: 10.1109/TR0.2017.2723903.
- [7] Sami Haddadin, Sven Parusel, Lars Johannsmeier, Saskia Golz, Simon Gabl, Florian Walch, Mohamadreza Sabaghian, Christoph Jähne, Lukas Hausperger, and Simon Haddadin. “The Franka Emika Robot: A Reference Platform for Robotics Research and Education”. In: *IEEE Robotics & Automation Magazine* 29.2 (2022), pp. 46–64. DOI: 10.1109/MRA.2021.3138382.

- [8] International Organization for Standardization. *ISO 9283:1998 – Manipulating industrial robots – Performance criteria and related test methods*. Tech. rep. Specifies methods for testing pose accuracy, repeatability, drift, and related performance characteristics of industrial manipulators. Geneva, Switzerland: ISO, 1998.
- [9] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. “Planning and Acting in Partially Observable Stochastic Domains”. In: *Artificial Intelligence* 101.1–2 (1998), pp. 99–134. DOI: 10.1016/S0004-3702(98)00023-X.
- [10] Sreekanth Kana, Jayati Gurnani, Vinayakumar Ramanathan, Sri Harsha Turlapati, Mohd Zulhilmi Ariffin, and Domenico Campolo. “Fast Kinematic Re-Calibration for Industrial Robot Arms”. In: *Sensors* 22.6 (2022). Evaluated on a Kinova Gen3 7-DOF arm. Reports per-joint angular offsets in the range $[-0.0084, 0.0088]$ rad after open-loop re-calibration., p. 2295. DOI: 10.3390/s22062295.
- [11] Michael Kelly, Chelsea Sidrane, Katherine Driggs-Campbell, and Mykel J. Kochenderfer. “HG-Dagger: Interactive Imitation Learning with Human Experts”. In: *2019 IEEE International Conference on Robotics and Automation (ICRA)*. Montreal, Canada, 2019, pp. 8077–8083. DOI: 10.1109/ICRA.2019.8793698.
- [12] Jonas Kiemel, Ludovic Righetti, Torsten Kröger, and Tamim Asfour. “Safe Reinforcement Learning of Robot Trajectories in the Presence of Moving Obstacles”. In: *IEEE Robotics and Automation Letters* 9.12 (2024). Also available as arXiv:2411.05784, pp. 11353–11360.
- [13] Jianlan Luo, Charles Xu, Jeffrey Wu, and Sergey Levine. “Precise and Dexterous Robotic Manipulation via Human-in-the-Loop Reinforcement Learning”. In: *Science Robotics* 10 (2025). Also available as arXiv:2410.21845, eads5033. DOI: 10.1126/scirobotics.ads5033.
- [14] Yuliang Ma, Philipp Grimmeisen, and Andrey Morozov. “Case Study: ROS-Based Fault Injection for Risk Analysis of Robotic Manipulator”. In: *2023 IEEE 19th International Conference on Automation Science and Engineering (CASE)*. University of Stuttgart, Institute of Industrial Automation and Software Engineering. 2023, pp. 1–6. DOI: 10.1109/CASE56687.2023.10260634.
- [15] Christian Ott. *Cartesian Impedance Control of Redundant and Flexible-Joint Robots*. Vol. 49. Springer Tracts in Advanced Robotics. Berlin, Heidelberg: Springer, 2008. ISBN: 978-3-540-69253-9. DOI: 10.1007/978-3-540-69255-3.
- [16] Stephane Ross, Geoffrey Gordon, and Drew Bagnell. “A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”. In: *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*

- (*AISTATS*). Vol. 15. Proceedings of Machine Learning Research. Fort Lauderdale, FL, USA: PMLR, 2011, pp. 627–635.
- [17] Bruno Siciliano, Lorenzo Sciavicco, Luigi Villani, and Giuseppe Oriolo. *Robotics: Modelling, Planning and Control*. Advanced Textbooks in Control and Signal Processing. London: Springer, 2010. ISBN: 978-1-84628-641-4.
- [18] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, Francisco Massa, Daniel Haziza, Luca Wehrstedt, Jianyuan Wang, Timothée Darcet, Théo Moutakanni, Leonel Sentana, Claire Roberts, Andrea Vedaldi, Jamie Tolan, John Brandt, Camille Couprie, Julien Mairal, Hervé Jégou, Patrick Labatut, and Piotr Bojanowski. *DINOv3*. 2025. DOI: 10.48550/arXiv.2508.10104. arXiv: 2508.10104 [cs.CV].
- [19] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2nd ed. Cambridge, MA: MIT Press, 2018. ISBN: 978-0-262-03924-6.
- [20] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. “Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World”. In: *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2017, pp. 23–30. DOI: 10.1109/IROS.2017.8202133.
- [21] Michal Vocetka, Zdenko Bobovský, Jan Babjak, Jaroslav Suder, Stefan Grushko, Jiri Mlotek, Vaclav Kryš, and Marek Hagara. “Influence of Drift on Robot Repeatability and Its Compensation”. In: *Applied Sciences* 11.22 (2021), p. 10813. DOI: 10.3390/app112210813.